

PROSIT 1 :

Préparation des

données par

apprentissage

non supervisé

TRAPPIER Quentin | MARCELLI Enzo | GOUADFEL Rayan | ARRIGHI Fabien
10 février 2026

Table des matières

1.	Contexte	2
2.	Mots inconnus / Clés	2
3.	Problématique.....	2
4.	Objectif.....	3
5.	Plan d'Action	3
6.	Réalisation	4
7.	Conclusion	5

1. Contexte

Dans le cadre de l'amélioration de ses services, l'agence immobilière Loft's Craft, implantée en Californie, souhaite exploiter un jeu de données immobilières afin de mieux comprendre la répartition des logements et d'optimiser ses propositions aux clients. L'objectif est de réduire les visites inutiles en identifiant des zones et profils de biens similaires, à partir de données issues du recensement californien de 1990.

Ce projet porte sur la préparation des données et la réalisation d'une analyse exploratoire, puis sur une première approche d'intelligence artificielle non supervisée pour regrouper automatiquement des logements.

2. Mots inconnus / Clés

- Analyse exploratoire des données (EDA)
- Clustering
- K-means
- Secteur de recensement (block group)
- Valeur médiane (median)
- Imputation (médiane / mode)
- Variables numériques / catégorielles
- Corrélation / heatmap
- Apprentissage supervisé vs non supervisé vs semi supervisé
- Évaluation de clustering : inertie, silhouette score (référence)

3. Problématique

Comment analyser et exploiter un jeu de données immobilier afin de regrouper automatiquement les logements en ensembles distincts, à partir de caractéristiques géographiques et socio-économiques, sans règles définies à l'avance ?

4. Objectif

L'objectif du travail réalisé est de :

- Comprendre la structure du dataset (colonnes, types, distribution).
- Nettoyer et préparer les données (valeurs manquantes, variables catégorielles).
- Mettre en évidence des tendances (géographie, revenus, valeur immobilière).
- Appliquer un algorithme de clustering (K-means) avec $k = 2$ pour obtenir deux groupes.
- Interpréter les clusters et vérifier leur cohérence vis-à-vis de la réalité géographique (zones côtières vs inland, SF/LA).

5. Plan d'Action

1. Mise en place de l'environnement d'analyse (Python, Jupyter, librairies data science).
2. Import et extraction du dataset immobilier depuis l'archive source.
3. Analyse structurelle du dataset :
 - Types de variables,
 - Distribution globale,
 - Détection valeurs manquantes,
 - Détection incohérences.
4. Nettoyage et préparation :
 - Imputation médiane pour variables numériques,
 - Imputation mode pour variables catégorielles,
 - Encodage variables catégorielles,
 - Normalisation si nécessaire pour clustering.
5. Analyse exploratoire avancée :
 - Distribution statistique des variables,
 - Analyse corrélation,
 - Analyse géographique longitude / latitude vs prix.
6. Construction dataset prêt ML :
 - Sélection features pertinentes,
 - Suppression des variables non informatives.
7. Application modèle non supervisé K-means :
 - Test $k = 2$,
 - Analyse inertie et cohérence cluster.
8. Analyse métier des clusters :
 - Comparaison zones géographiques,
 - Cohérence économique (revenus / prix).
9. Documentation pipeline pour reproductibilité.

6. Réalisation

Une analyse exploratoire complète du jeu de données sera réalisée afin de comprendre précisément la distribution des variables et les relations statistiques entre elles.

Les valeurs manquantes seront identifiées puis traitées à l'aide de méthodes d'imputation adaptées afin d'obtenir un dataset propre, cohérent et exploitable pour l'apprentissage automatique.

Des visualisations statistiques et géographiques seront produites afin d'identifier les tendances principales du dataset, notamment le lien entre localisation géographique et valeur immobilière.

L'analyse exploratoire permet également d'identifier les zones géographiques à forte valeur immobilière et de mieux comprendre les relations entre revenus des ménages, localisation et prix du logement, ce qui constitue un levier direct d'optimisation commerciale pour l'agence.

Le dataset sera ensuite préparé pour une utilisation en machine learning via :

- Sélection des variables pertinentes,
- Transformation des variables catégorielles,
- Mise à l'échelle des données si nécessaire.

L'algorithme K-means sera appliqué avec un nombre de clusters fixé à 2 afin de segmenter automatiquement les logements selon leurs caractéristiques.

Les clusters obtenus seront analysés afin de vérifier leur cohérence avec la réalité géographique et économique, notamment la différenciation entre zones côtières et zones intérieures ainsi que les grandes zones urbaines majeures.

L'ensemble du pipeline sera documenté afin de garantir la reproductibilité complète dans le notebook du projet.

7. Conclusion

Ce prosit permet de mettre en place les bases techniques et méthodologiques nécessaires à un projet d'intelligence artificielle appliqué à la donnée immobilière.

La préparation rigoureuse des données et l'analyse exploratoire constituent des étapes essentielles pour garantir la qualité des modèles futurs.

K-means a été retenu car il permet une segmentation naturelle des données numériques sans supervision préalable. Il est adapté aux datasets volumineux et permet une première structuration rapide des données. Cependant, il reste sensible au choix du nombre de clusters et aux valeurs extrêmes, ce qui devra être pris en compte dans les phases suivantes du projet.

L'utilisation d'un algorithme de clustering non supervisé permet d'identifier des structures naturelles dans les données sans hypothèse préalable, offrant ainsi une première approche d'analyse intelligente exploitable métier.

Les résultats obtenus permettront d'orienter les étapes suivantes du projet, notamment vers des approches supervisées plus avancées, tout en conservant une logique d'interprétation métier.

Le travail réalisé s'inscrit dans une démarche reproductible, explicable et alignée avec les bonnes pratiques data science attendues dans un contexte professionnel. Les résultats devront être interprétés avec précaution afin d'éviter toute utilisation automatique ou biaisée des données, notamment liée aux disparités géographiques ou socio-économiques présentes dans le dataset.