



BLOC INTELLIGENCE ARTIFICIELLE (MACHINE LEARNING)



Concepteur du projet : **Mickael DELAMARE**
Contributeur au projet : **Ilyass ABOUELAZIZ, Mohamed Amin BENATIA,
Leila BEN LETAIFA, Ramzi CHAIEB, Zakariya GHALMANE, Vincent
HAVARD, Youssef MOURCHID, Rim SALMI**

CESI 
ÉCOLE D'INGÉNIEURS

Table des matières

Objectifs d'apprentissage	4
Introduction	6
I - Guide pédagogique	7
1. Aide au tutorat	7
2. Ressources pour les tuteurs.....	7
II - Préparation	8
Objectifs d'apprentissage	8
1. Sujet	8
1.1. Énoncé	8
1.2. Ressources pour les étudiants.....	9
2. Guide pédagogique	9
2.1. Aide au tutorat.....	9
2.2. Ressources pour les tuteurs	9
III - Projet	10
Objectifs d'apprentissage	10
1. Sujet	10
1.1. IA for HumanForYou	10
1.2. Livrables attendus	12
2. Guide pédagogique	13
2.1. Aide au tutorat.....	13
2.2. Ressources pour les tuteurs	13
IV - Boucle Utilisation de l'intelligence artificielle	14
1. 1-Boucle PBL.....	14
Objectifs d'apprentissage	14
Prérequis	14
1.1. Sujet	14
1.2. Guide pédagogique	17
2. Workshop du prosit 1.....	23
2.1. Sujet	23
2.2. Guide pédagogique	24
V - Boucle Prédiction de données	25
1. 2-Boucle PBL.....	25
Objectifs d'apprentissage	25
1.1. Sujet	25
1.2. Guide pédagogique	26
2. Workshop du prosit 2.....	29
2.1. Sujet	29
2.2. Guide pédagogique	29

VI - Boucle IA pour la classification supervisée	30
1. 3-Boucle PBL.....	30
Objectifs d'apprentissage	30
1.1. Sujet	30
1.2. Guide pédagogique	31
2. Workshop du prosit 3.....	39
2.1. Sujet	39
2.2. Guide pédagogique	39
Ressources	40



Objectifs d'apprentissage

Séquence de préparation

- [2] Identifier les principales commandes Python nécessaires à l'installation et à l'utilisation de Jupyter Notebook.
- [1] Lister les étapes nécessaires pour configurer un environnement de développement pour l'analyse de données.

Analyse exploratoire des données

- [3] Appliquer les techniques de préparation des données pour une tâche de machine learning (ML).
- [3] Implémenter une analyse exploratoire des données (EDA) en utilisant Python.
- [4] Analyser les données en utilisant des techniques d'EDA pour identifier des tendances et des modèles.
- [6] Concevoir un pipeline d'analyse exploratoire des données en intégrant des statistiques descriptives et des prétraitements.
- [4] Identifier des valeurs manquantes et savoir les éliminer.
- [3] Appliquer la normalisation et la standardisation des données.

Régression linéaire et non linéaire

- [1] Identifier une tâche de régression à partir d'un jeu de données ou d'une application réelle.
- [1] Lister les différents types de régression linéaire (simple, multiple) et non-linéaire (polynomiale, logistique, etc.).
- [4] Analyser les performances des modèles de régression en utilisant des métriques telles que le coefficient de détermination (R^2) et l'erreur quadratique moyenne (MSE).
- [5] Estimer la pertinence et l'efficacité des modèles développés pour résoudre les tâches assignées.
- [6] Proposer des améliorations pour les modèles de régression linéaire et non-linéaire en fonction des résultats obtenus et des analyses de résidus.
- [2] Citer des modèles développés pour résoudre les tâches assignées.

Classification et clustering

- [3] Appliquer des techniques de classification sur des jeux de données pour identifier des catégories ou des ensembles de données en groupes significatifs.
- [1] Lister les différents algorithmes de classification et de clustering utilisés en machine learning.
- [4] Expliquer les principes de base des algorithmes de classification et de clustering (e.g., k-NN, arbres de décision, SVM).
- [4] Analyser les performances des modèles de classification à l'aide de métriques telles que la précision, le rappel, et la F-mesure.
- [6] Combiner plusieurs techniques de prétraitement et d'algorithmes pour optimiser les résultats de classification et de clustering.
- [5] Évaluer la qualité des clusters formés en utilisant des indices comme la silhouette score et le coefficient de Davies-Bouldin.
- [2] Définir les concepts de classification et de clustering et leurs différences fondamentales.

Présentation orale et compréhension

- [6] Créer des solutions innovantes pour améliorer les modèles de ML en fonction des résultats obtenus.
- [5] Présenter les résultats du projet de manière claire et concise devant un jury évaluateur.
- [5] Défendre les choix méthodologiques et les résultats obtenus lors de la soutenance.

- [4] Critiquer les politiques et les pratiques actuelles en matière d'éthique et de durabilité dans l'IA.
- [5] Défendre l'importance d'une approche éthique et durable dans le développement et l'implémentation des technologies d'IA.

Introduction

Ce bloc a pour objectif de vous faire découvrir l'intelligence artificielle. Il permettra de fournir les bases pour suivre l'option Datascience en A5. Par conséquent, on se concentrera sur une petite partie de ce que l'on appelle IA.

Les objectifs sont les suivants :

- Explorer l'évolution historique de l'intelligence artificielle (IA) pour comprendre les bases et le contexte des avancées actuelles
- Identifier et analyser les enjeux éthiques de l'IA, y compris la confidentialité, les biais et l'impact sociétal
- Apprendre à collecter, nettoyer et préparer des jeux de données pour les adapter aux modèles d'apprentissage machine
- Maîtriser les techniques de régression pour estimer des valeurs numériques et de classification pour prédire des catégories, et savoir évaluer leurs performances
- Améliorer et évaluer les performances de vos modèles avec des stratégies d'apprentissage telles que l'échantillonnage, la validation croisée, la recherche d'hyperparamètres et la régularisation

Objectif du Bloc :

L'objectif de ce bloc est de découvrir les bases du Machine Learning dans le contexte de l'intelligence artificielle (IA). Le programme est divisé en trois parties : l'Analyse Exploratoire des Données (EDA) et la visualisation, la Régression (linéaire et non-linéaire), et enfin, le Clustering et la Classification.

Outils Utilisés :

Ce bloc utilise des outils comme Jupyter Notebook en Python, étendu avec des bibliothèques dédiées à l'IA telles que Seaborn (sns), Plotly, Matplotlib, StatModel, et Scikit-Learn. L'accent est mis sur la mise en place d'un processus, d'un workflow, et d'un pipeline de traitement de données complet.

Vision d'Ensemble :

L'objectif est de fournir une vision d'ensemble de l'intelligence artificielle, permettant aux participants d'expérimenter pour la première fois à travers des projets et des travaux pratiques. Une attention particulière est portée à l'analyse des résultats et à la réflexion sur les dimensions éthiques liées à ce type de projet.

1. Aide au tutorat

Ne pas hésiter à parler de l'option "Data scientist" qui vient en continuité de ce bloc en poussant l'aspect Deep Learning.

2. Ressources pour les tuteurs

PROJET IA - GRILLE EVALUATION.xlsx (cf. PROJET IA - GRILLE EVALUATION.xlsx)

Pour la partie Ethique : Il n'y a que 2 objectifs qui ne peuvent pas se compenser l'un l'autre. La forme du document n'est pas évaluée en soi mais en cas de dérive, sanctionner sur l'implication dans la formation.

Objectifs d'apprentissage

[2] Identifier les principales commandes Python nécessaires à l'installation et à l'utilisation de Jupyter Notebook.

[1] Lister les étapes nécessaires pour configurer un environnement de développement pour l'analyse de données.

[2] Retracer l'histoire de l'I.A. [2] Identifier les domaines d'application de l'I.A.

[2] Identifier les acteurs de l'I.A. et les solutions proposées.

[4] Détecter les problématiques éthiques liées à l'I.A. dans un contexte donné.

1. Sujet

1.1. Énoncé

a) Exercice : Ouverture du bloc

Prise en main de Jupyter Notebook

Vous trouverez ici¹ une petite vidéo permettant de reprendre rapidement en main l'outil Jupyter (vous pouvez aussi utiliser l'outil JupyterLab, qui est plus proche d'un IDE).

Voici un premier notebook Jupyter permettant de se familiariser avec certains outils mathématiques de base dans l'environnement Python :

Tuto algèbre linéaire avec Python (cf. tutoLinAlg.ipynb)

Conférence Nationale - Introduction à l'IA - Mohamed Amin BENATIA - CESI-LINEACT

Introduction à l'IA - M. A. BENATIA - LINEACT²

Atelier Éthique

La première question à se poser est de bien redéfinir ce que l'on appelle "éthique".

Ethique vidéo 01 - Définitions³ (4m08)

A partir de cette définition, nous vous proposons de découvrir une méthodologie de réflexion dans la vidéo suivante :

Ethique vidéo 02 - Méthode⁴ (6m14)

En petits groupes (6 élèves), réfléchissez à votre réponse à une problématique éthique proposée par votre enseignant en mettant en œuvre la méthodologie de réflexion proposée dans la vidéo précédente⁵. (durée : 15 minutes)

Chaque groupe présente en 3 minutes sa décision et les raisons de cette décision.

Ethique vidéo 05 - Décision valeurs⁶ (4m56)

Vous devrez approfondir cette réflexion tout au long du projet, afin d'intégrer une démarche éthique dans les différentes phases de votre travail en groupe. Vous présenterez cette réflexion lors de votre soutenance finale.

1. https://www.youtube.com/watch?v=g2yckh3_22E

2. Lien direct vers la conférence - <https://embed.api.video/vod/vi3btqdmMa0SzoWRJzFIVxI0>

3. <https://embed.api.video/vod/vi1AGvh3tdJiZ149wyIFLpS8>

4. <https://embed.api.video/vod/vi3rd8CIsylBfER8a9VqGACw>

5. <https://embed.api.video/vod/vi3rd8CIsylBfER8a9VqGACw>

6. <https://embed.api.video/vod/vi64G0jyfsWsJDfKAm3LESla>

1.2. Ressources pour les étudiants

Ouvrage de référence

Le guide de l'intelligence artificielle au travail (vos droits face aux algorithmes) - Franca Salis-Madinier - Éditions Eyrolles⁷

L'éthique IA

Ethique p. 40

2. Guide pédagogique

2.1. Aide au tutorat

Atelier éthique - Guide tuteur

Une deuxième couche sur l'éthique sera abordée dans le cadre du projet de Recherche et Innovation.

L'objectif est de les préparer à la prise de décision dans le cadre d'un dilemme éthique.

Avant de lancer les vidéos, leur poser la question de ce qu'est l'éthique pour eux, la morale ? C'est quoi un dilemme éthique ?

Consulter les 2 vidéos suivantes :

Ethique - Vidéo 01 - Définitions⁸ (4m07)

Ethique - Vidéo 02 - Méthode⁹ (6m14)

En petits groupes (6 élèves), réfléchissez en mettant en œuvre la méthodologie proposée dans la vidéo précédente à votre réponse à une problématique éthique proposée par votre enseignant. (durée : 15 minutes)

Vous pouvez choisir un sujet les touchant de près : Le BDE organise une soirée et une semaine avant, on leur annonce que la salle ne sera pas disponible suite à un souci technique. Le bureau ne trouve que 2 salles disponibles aux alentours : une à 50 km qui pourrait accueillir tout le monde et une plus proche mais qui ne permettrait pas d'accueillir tout le monde.

Ou, si vous sentez votre groupe assez mature, les amener sur des problématiques plus liées à l'IA : Dans votre entreprise que vous savez en difficultés financières, on vous demande de mettre en place une solution d'IA s'appuyant sur les systèmes de messagerie internes de l'entreprise pour remonter aux managers un indicateur sur l'état d'esprit (très positif, positif, neutre ou négatif) de leurs subordonnés dans le but d'accompagner ce passage difficile.

Chaque petit groupe présente en 3 minutes sa décision et les raisons de cette décision.

Demander au groupe ce qui a été facile, ce qui ne l'a pas été.

Leur ressenti pendant l'exercice.

Puis ouvrir vers des problèmes d'actualité, de leur vie professionnelle (vécue et future) et qu'ils se posent la question au sein de l'école ou leur vie personnelle.

Pour conclure la séance :

Ethique Vidéo 05 - Décision valeurs¹⁰ (4m56)

« On leur demande d'appliquer la méthodologie proposée sur leur projet. Vous pourrez vous positionner comme membre de la direction de l'entreprise pour répondre à leurs questions. »

2.2. Ressources pour les tuteurs

Ce support peut aider à accompagner la séance :

Ethique p. 40

7. <https://univ.scholarvox.com/catalog/book/docid/88923208>

8. <https://embed.api.video/vod/vi1AGvh3tdJiZ149wyIFLpS8>

9. <https://embed.api.video/vod/vi3rd8CIsylBfER8a9VqGACw>

10. <https://embed.api.video/vod/vi64G0jyfsWsJDfKAm3LESla>

Objectifs d'apprentissage

Présentation orale et compréhension

[6] Créer des solutions innovantes pour améliorer les modèles de ML en fonction des résultats obtenus.

[5] Présenter les résultats du projet de manière claire et concise devant un jury évaluateur.

[5] Défendre les choix méthodologiques et les résultats obtenus lors de la soutenance.

[4] Critiquer les politiques et les pratiques actuelles en matière d'éthique et de durabilité dans l'IA.

[5] Défendre l'importance d'une approche éthique et durable dans le développement et l'implémentation des technologies d'IA.

1. Sujet

1.1. IA for HumanForYou

L'entreprise pharmaceutique HumanForYou, basée en Inde, emploie environ 4000 personnes. Cependant, chaque année, elle connaît un taux de rotation d'environ 15 % de ses employés, ce qui nécessite de trouver des profils similaires sur le marché de l'emploi.

La direction considère que ce niveau de rotation n'est pas bénéfique pour l'entreprise pour les raisons suivantes :

- Les projets sur lesquels travaillaient les employés quittant la société prennent du retard, ce qui nuit à la réputation de l'entreprise auprès de ses clients et partenaires.
- Il est nécessaire de conserver un service des ressources humaines conséquent afin d'avoir les moyens de trouver de nouveaux employés.
- L'arrivée des nouveaux employés entraîne une perte de temps, car ils doivent souvent être formés et ont besoin d'un certain temps pour être pleinement opérationnels dans leur nouvel environnement.

La direction fait donc appel à vous, spécialistes de l'analyse de données, pour déterminer les facteurs ayant le plus d'influence sur ce taux de rotation et pour proposer des modèles afin d'identifier des pistes d'amélioration permettant de motiver les employés à rester dans l'entreprise.

Données fournies

Un certain nombre de données concernant les employés vous ont donc été transmises par le service des ressources humaines.

Il s'agit de fichiers texte au format CSV.

Les données ont été anonymisées : chaque employé de l'entreprise sera représenté par le même EmployeeID dans l'ensemble des fichiers qui suivent.

Données du service des ressources humaines

Pour chaque employé, le service des ressources humaines vous confie les informations en sa possession :

- Age : L'âge de l'employé en 2015.
- Attrition : L'objet de notre étude, est-ce que l'employé a quitté l'entreprise durant l'année 2016 ?
- BusinessTravel : A quelle fréquence l'employé a-t-il été amené à se déplacer dans le cadre de son travail en 2015 ? (Non-Travel = jamais, Travel_Rarely= rarement, Travel_Frequently = fréquemment).
- DistanceFromHome : Distance en km entre le logement de l'employé et l'entreprise.

- Education : Niveau d'étude : 1=Avant College (équivalent niveau Bac), 2=College (équivalent Bac+2), 3=Bachelor (Bac+3), 4=Master (Bac+5) et 5=PhD (Thèse de doctorat).
- EducationField : Domaine d'étude, matière principale.
- EmployeeCount : booléen à 1 si l'employé était compté dans les effectifs en 2015.
- EmployeeId : l'identifiant d'un employé.
- Gender : Sexe de l'employé.
- JobLevel : Niveau hiérarchique dans l'entreprise de 1 à 5.
- JobRole : Métier dans l'entreprise.
- MaritalStatus : Statut marital du salarié (Célibataire, Marié ou Divorcé).
- MonthlyIncome : Salaire brut en roupies par mois.
- NumCompaniesWorked : Nombre d'entreprises pour lesquelles le salarié a travaillé avant de rejoindre HumanForYou.
- Over18 : Est-ce que le salarié a plus de 18 ans ou non ?
- PercentSalaryHike : % d'augmentation du salaire en 2015.
- StandardHours : Nombre d'heures par jour dans le contrat du salarié.
- StockOptionLevel : Niveau d'investissement en actions de l'entreprise par le salarié.
- TotalWorkingYears : Nombre d'années d'expérience en entreprise du salarié pour le même type de poste.
- TrainingTimesLastYear : Nombre de jours de formation en 2015.
- YearsAtCompany : Ancienneté dans l'entreprise.
- YearsSinceLastPromotion : Nombre d'années depuis la dernière augmentation individuelle.
- YearsWithCurrentManager : Nombre d'années de collaboration sous la responsabilité du manager actuel de l'employé.

(cf. general_data.csv)

Dernière évaluation du manager

Ce fichier contient la dernière évaluation de chaque employé faite par son manager en février 2015.

Il contient les données suivantes :

- L'identifiant de l'employé : EmployeeId
- Une évaluation de son implication dans son travail notée 1 ('Faible'), 2 ('Moyenne'), 3 ('Importante') ou 4 ('Très importante') : JobInvolvement
- Une évaluation de son niveau de performance annuel pour l'entreprise notée 1 ('Faible'), 2 ('Bon'), 3 ('Excellent') ou 4 ('Au delà des attentes') : PerformanceRating

(cf. manager_survey_data.csv)

Enquête qualité de vie au travail

Ce fichier provient d'une enquête soumise aux employés en juin 2015 par le service RH pour avoir un retour concernant leur qualité de vie au travail.

Une organisation avait été mise en place pour que chacun puisse répondre à ce questionnaire sur son lieu de travail en concertation avec les managers mais il n'y avait pas d'obligation.

Les employés devaient répondre à 3 questions sur le niveau de satisfaction concernant :

- l'environnement de travail, noté 1 ('Faible'), 2 ('Moyen'), 3 ('Élevé') ou 4 ('Très élevé') : EnvironmentSatisfaction
- son travail, noté de 1 à 4 comme précédemment : JobSatisfaction
- son équilibre entre vie professionnelle et vie privée, noté 1 ('Mauvais'), 2 ('Satisfaisant'), 3 ('Très satisfaisant') ou 4 ('Excellent') : WorkLifeBalance

Lorsqu'un employé n'a pas répondu à une question, le texte "NA" apparaît à la place de la note.

(cf. employee_survey_data.csv)

Horaires de travail

Des badgeuses sont installées et utilisées dans l'entreprise depuis quelques années. Il a été jugé opportun par la direction de vous transmettre les horaires d'entrée et de sortie des employés sur une période de l'année choisie représentative d'une activité moyenne pour l'ensemble des services.

Vous trouverez donc 2 fichiers qui retracent les horaires d'arrivée à leur poste et de départ de leur poste pour l'ensemble des employés par date sur une période allant du 1er janvier au 31 décembre 2015.

(cf. in_out_time.zip)

Sources :

Les données de ce projet sont des données générées issues de ce projet sur Kaggle : <https://www.kaggle.com/vjchoudhary7/hr-analytics-case-study>

Vous êtes attendus sur votre capacité à exploiter les données fournies pour répondre aux besoins de l'entreprise qui vous a sollicités. Vous pouvez vous inspirer d'approches faites par d'autres personnes, mais vous devrez être en mesure d'expliquer chacun des choix retenus en les justifiant.

1.2. Livrables attendus

Projet I.A. - Livrable : éthique

Il s'agit d'un document mettant en évidence votre appropriation de la méthodologie proposée pour adopter une démarche éthique en justifiant vos choix, en tenant compte des échanges au sein de votre équipe tout au long du projet, depuis la préparation des données jusqu'à la proposition de pistes d'amélioration à votre client. En plus de la démarche, vous devrez mettre en évidence les décisions prises en équipe ainsi que les points de vigilance ou de contrôle à mettre en place concernant les problématiques éthiques rencontrées.

Pour vous guider dans cette démarche, vous pouvez vous appuyer sur les questions accessibles depuis ce site¹¹. Le fichier PDF téléchargeable contient les principales questions à se poser pour évaluer l'éthique d'un projet d'IA, selon les 7 exigences recommandées par la Commission Européenne :

- Respect de l'autonomie humaine.
- Robustesse technique et sécurité.
- Confidentialité et gouvernance des données.
- Transparence.
- Diversité, non-discrimination et équité.
- Bien-être environnemental et sociétal.
- Responsabilité.

Projet I.A. - Livrable : Bibliographie

Il s'agit d'un document visant à présenter les références académiques et techniques que vous avez utilisées pour orienter votre travail, en indiquant leur pertinence dans la compréhension des concepts abordés. Ce document inclut des sources permettant de justifier vos choix, de valider les méthodes employées et de guider les prises de décision dans le cadre de votre projet. En plus de citer les ouvrages et articles, il est essentiel de souligner les apports de chaque source ainsi que leur impact sur le développement de votre démarche.

Pour organiser votre bibliographie, vous pouvez classer les sources par thématique :

- **Sources méthodologiques et théoriques** : références traitant des bases théoriques et des modèles méthodologiques employés.
- **Sources sur les aspects techniques** : ouvrages ou articles décrivant les techniques spécifiques utilisées.

¹¹ <https://digital-strategy.ec.europa.eu/en/library/assessment-list-trustworthy-artificial-intelligence-altai-self-assessment>

- **Sources éthiques et sociétales** : ressources relatives aux normes et aux enjeux éthiques dans votre domaine.
- **Sources spécifiques au projet** : articles, études de cas ou rapports ayant directement inspiré ou orienté vos choix.

Pour chaque source, veuillez à inclure :

- Le respect des droits d'auteur et des licences de publication.
- Une brève annotation justifiant l'intégration de chaque source dans votre bibliographie.

Projet I.A. - Présentation

Il s'agit de votre présentation intégrant votre notebook Jupyter (qui sera envoyé la veille de la soutenance) et votre présentation de 20 minutes qui devra montrer l'ensemble de votre démarche :

- La génération de votre/vos jeux de données en justifiant les choix et les traitements effectués pour faire face aux problématiques classiques de ce type de travail.
- Le choix de l'algorithme ou des algorithmes d'IA sélectionnés.
- L'analyse des résultats obtenus et leur interprétation en se basant sur des métriques.
- La démarche mise en œuvre pour améliorer un modèle.
- Le choix du modèle retenu au final parmi les différents essais effectués en justifiant par rapport au besoin de votre client et des métriques.
- Vos propositions finales justifiées.

2. Guide pédagogique

2.1. Aide au tutorat

Attention, il s'agit de données générées, donc il peut y avoir des incohérences par rapport à ce que l'on trouverait dans la réalité (comme les salaires par rapport aux postes et les niveaux d'études, par exemple). Il est important de les informer de cela pour éviter toute surprise. Cependant, cela ne remet pas en question l'exercice de réflexion et la démarche attendue, qui restent similaires à ce que l'on pourrait attendre d'eux en entreprise.

Sur le plan technique, après avoir effectué un travail approfondi d'exploration et de préparation des données, on peut attendre des élèves qu'ils mettent en œuvre une régression logistique. En effet, ils disposent des éléments nécessaires pour effectuer un apprentissage supervisé en se basant sur le champ "Attrition" (indiquant si l'employé a quitté l'entreprise dans l'année), qui est une variable booléenne.

Les instructions sont volontairement formulées de manière vague pour laisser aux élèves une marge de réflexion suffisamment large et leur permettre de nous surprendre.

Les données sont issues de ce projet sur Kaggle : <https://www.kaggle.com/vjchoudhary7/hr-analyti cs-case-study>

2.2. Ressources pour les tuteurs

Grille d'évaluation du projet

Voir dans la partie Guide tuteur du lancement du projet

Boucle Utilisation de l'intelligence artificielle

IV

1. 1-Boucle PBL

Objectifs d'apprentissage

Séquence de préparation

[2] Identifier les principales commandes Python nécessaires à l'installation et à l'utilisation de Jupyter Notebook.

[1] Lister les étapes nécessaires pour configurer un environnement de développement pour l'analyse de données.

[2] Identifier les acteurs de l'I.A. et les solutions proposées.

[4] Détecter les problématiques éthiques liées à l'I.A. dans un contexte donné.

Analyse exploratoire des données

[3] Appliquer les techniques de préparation des données pour une tâche de machine learning (ML).

[3] Réaliser une analyse exploratoire des données (EDA) avec Python pour mieux comprendre un jeu de données.

[4] Utiliser les techniques d'EDA pour identifier des tendances et des corrélations.

[6] Concevoir un pipeline d'analyse exploratoire des données en intégrant des statistiques descriptives et des prétraitements des données.

[4] Détecter les valeurs manquantes et appliquer les stratégies d'imputations.

[3] Mettre en œuvre la normalisation et la standardisation des données.

1.1. Prérequis

Objectifs d'apprentissage

Algorithmique Environnement python

1.2. Sujet

a) Énoncé

i) Exercice : On sépare les appartements

Contexte et Objectif :

L'agence immobilière Loft's Craft, basée en Californie, est reconnue pour sa qualité de service et son excellent bouche-à-oreille, attirant à la fois des clients particuliers et professionnels. Afin d'optimiser ses propositions de biens immobiliers et de réduire le nombre de visites nécessaires, y compris virtuelles, l'agence envisage de recourir à l'intelligence artificielle.

Solution Envisagée :

L'intelligence artificielle offre de nombreuses possibilités pour améliorer les services de Loft's Craft. Une étude est en cours pour identifier les meilleures applications de l'IA adaptées à leurs besoins. En attendant, un jeu de données issu du recensement de 1990, correspondant à la zone géographique couverte par l'agence, a été récupéré pour être exploité.

Description du Jeu de Données :

Le jeu de données comprend des informations sur les maisons et leurs habitants, regroupées par secteur de recensement, une zone homogène en termes de démographie et d'économie. Voici les principales colonnes :

- **longitude** : Mesure de la longitude centroïde d'un secteur de recensement. Plus la valeur est élevée, plus il se trouve à l'ouest (varie de -124,3 à -114,3).
- **latitude** : Mesure de la latitude centroïde d'un secteur de recensement. Plus la valeur est élevée, plus il se trouve au nord (varie de 32,5 à 42,5).
- **housing_median_age** : Âge médian des logements dans le secteur (varie de 1 à 52 ans).
- **total_rooms** : Nombre total de pièces dans un secteur (varie de 2 à 37,937).
- **total_bedrooms** : Nombre total de chambres dans un secteur (varie de 1 à 6,445, certaines valeurs peuvent être manquantes).
- **population** : Nombre total de résidents dans un secteur (varie de 3 à 35,682).
- **households** : Nombre total de foyers dans un secteur (varie de 1 à 6,082).
- **median_income** : Revenu médian des foyers dans un secteur (varie de 0,5 à 15 dizaines de milliers de dollars).
- **median_house_value** : Valeur médiane des logements dans un secteur (varie de 14,999 à 500,001 dollars).
- **ocean_proximity** : Proximité par rapport à l'océan, avec des valeurs comme INLAND, <1 OCEAN, NEAR OCEAN, NEAR BAY, ISLAND.

Préparation des Données :

Dans cette boucle, nous allons préparer notre jeu de données pour l'analyse et l'apprentissage automatique. Cela inclut l'importation des données, l'identification et la gestion des valeurs manquantes, et la création de visualisations pour une meilleure compréhension des données. Nous suivrons le processus suivant :

1. Importation des données : Tout d'abord, nous allons importer les bibliothèques nécessaires et configurer notre environnement pour une meilleure lisibilité des données et des graphiques.

2. Chargement et exploration des données : Nous commençons par charger les données du fichier CSV extrait d'une archive .tgz. Ensuite, nous explorons la structure du jeu de données pour obtenir un aperçu des colonnes, des types de données et des valeurs manquantes.

3. Compréhension des données : dans cette phase nous produirons un résumé du jeu de données pour comprendre la distribution des variables et identifier les valeurs manquantes. Les méthodes `info()` et `describe()` de pandas sont utilisées pour fournir des résumés concis et des statistiques descriptives.

4. Gestion des valeurs manquantes : Pour simplifier, nous remplissons les valeurs manquantes dans les colonnes numériques avec la valeur médiane de chaque colonne. Pour les colonnes catégorielles, nous utilisons la valeur la plus fréquente (mode) pour l'imputation.


5. Visualisation des données : Nous utilisons diverses visualisations pour analyser la distribution des données et les relations entre les variables. Cela inclut des histogrammes pour les caractéristiques numériques, des diagrammes en barres pour les caractéristiques catégorielles, des cartes de chaleur pour les corrélations et des cartes géographiques pour la visualisation spatiale des prix des maisons.

Cette préparation des données nous permet de transformer notre jeu de données brut en un format propre et prêt pour les analyses ultérieures et les modèles d'apprentissage automatique.

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value
count	20640.00	20640.00	20640.00	20640.00	20433.00	20640.00	20640.00	20640.00	20640.00
mean	-119.57	35.63	28.64	2635.76	537.87	1425.48	499.54	3.87	208855.82
std	2.00	2.14	12.59	2181.62	421.39	1132.46	382.33	1.90	115395.62
min	-124.35	32.54	1.00	2.00	1.00	3.00	1.00	0.50	14999.00
25%	-121.80	33.93	18.00	1447.75	296.00	787.00	280.00	2.56	119600.00
50%	-118.49	34.26	29.00	2127.00	435.00	1166.00	409.00	3.53	179700.00
75%	-118.01	37.71	37.00	3148.00	647.00	1725.00	605.00	4.74	264725.00
max	-114.31	41.95	52.00	39320.00	6445.00	35682.00	6082.00	15.00	500001.00

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   longitude             20640 non-null  float64
1   latitude              20640 non-null  float64
2   housing_median_age    20640 non-null  float64
3   total_rooms           20640 non-null  float64
4   total_bedrooms        20433 non-null  float64
5   population            20640 non-null  float64
6   households            20640 non-null  float64
7   median_income         20640 non-null  float64
8   median_house_value    20640 non-null  float64
9   ocean_proximity       20640 non-null  object
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

Density Heatmap of House Prices



Les résultats semblent prometteurs, les points rouges semblent correspondre à des zones où l'immobilier est plus cher : au Nord avec les environs de San Francisco et la côte sud avec notamment Los Angeles...

On lui a conseillé d'utiliser l'algorithme de K-means qui devrait donner de meilleurs résultats en préparant au mieux son jeu de données de manière à exploiter le potentiel de l'ensemble des données fournies.

Cet algorithme serait capable de séparer les données de la base en k parties (ici k=2) parties distinctes sans aucun paramètres préalables ! Uniquement par une analyse intelligente des données entre elles ! C'est génial !

b) Ressources pour les étudiants

Définition et éthique

CNIL - Comment permettre à l'Homme de garder la main ?¹²

Préparation des données

Conférence DataWrangling¹³ : Conférence Mohamed-Amin BENATIA - Déc. 2020

BasicsStatisticsForDataScience (cf. *BasicsStatisticsForDataScience.pdf*) : Support de la conférence

Conseils d'IBM¹⁴

Standardisation et Normalisation¹⁵

Algorithmes de classification automatique (non supervisés)

Apprentissage supervisé et non-supervisé¹⁶

12. https://www.cnil.fr/sites/default/files/atoms/files/cnil_rapport_garder_la_main_web.pdf

13. <https://www.youtube.com/watch?v=MmGly3nB8hI&feature=youtu.be>

14. <https://www.ibm.com/downloads/cas/BN7ZELVZ>

15. <https://www.kdnuggets.com/2020/04/data-transformation-standardization-normalization.html>

16. <https://le-datascientist.fr/apprentissage-supervise-vs-non-supervise>

Classification Ascendante Hiérarchique¹⁷ et en plus poussé ce lien¹⁸ (pour approfondir)

Présentation K-means¹⁹

Possibilités de K-means²⁰

Techniques de l'ingénieur : IA

Machine learning et données²¹

IA et éthique²²

Objectivité de l'IA²³

IA et transformation numérique²⁴

IA et données en entreprise²⁵

IA et avenir²⁶

IA pour les ventes²⁷

Ouvrages de référence

Python Data Science Handbook, Jake VanderPlas : <https://jakevdp.github.io/PythonDataScienceHandbook/> (version complète disponible en ligne)

Pour aller plus loin

Artificial Intelligence with Pythons de Joshi, Prateek : <https://univ.scholarvox.com/catalog/book/docid/88842652?searchterm=artificial%20intelligence>

1.3. Guide pédagogique

a) Aide au tutorat

Philosophie du prosit

Le prosit propose un cadre de réflexion autour de l'IA, en mettant particulièrement l'accent sur le prétraitement des données. L'objectif n'est pas de prédire des valeurs ou des catégories, mais plutôt de se concentrer sur le traitement des données. Les questions principales abordées sont :

- Comment traiter les données non numériques ?
- Comment gérer les valeurs manquantes ?
- Comment traiter les données aberrantes (outliers) ?

Pour un modèle d'apprentissage machine donné, comment s'assurer que les données en entrée de cet algorithme seront adaptées pour en tirer les meilleurs résultats ?

Suite à la conférence d'ouverture, ce prosit offre également l'opportunité d'explorer les domaines d'application de l'IA et de réfléchir aux enjeux éthiques associés. Cependant, il est crucial de veiller à ce que les étudiants ne négligent pas la partie prétraitement des données en se focalisant uniquement sur les algorithmes de classification automatique ou les domaines d'application de l'IA.

Notes au tuteur, conseils, trucs et astuces

17. <https://datascientest.com/machine-learning-clustering-focus-sur-algorithme-cah>

18. <http://pbil.univ-lyon1.fr/R/pdf/stage7.pdf>

19. <https://datascientest.com/algorithme-des-k-means>

20. <https://ledatascientist.com/faire-du-clustering-avec-lalgorithme-k-means/>

21. <https://www.techniques-ingenieur.fr/actualite/articles/le-machine-learning-et-le-deep-learning-optimisent-les-donnees-des-entreprises-83158/>

22. <https://www.techniques-ingenieur.fr/actualite/articles/lintelligence-artificielle-entre-excitation-et-ethique-72281/>

23. <https://www.techniques-ingenieur.fr/actualite/articles/lintelligence-artificielle-nest-pas-objective-81131/>

24. <https://www.techniques-ingenieur.fr/base-documentaire/innovation-th10/industrie-du-futur-outils-numeriques-42669210/intelligence-artificielle-dans-le-cadre-de-la-transformation-numerique-h9000/>

25. <https://www.techniques-ingenieur.fr/actualite/livre-blanc/lintelligence-artificielle-en-entreprise-une-force-tributaire-des-donnees-82126/>

26. <https://www.techniques-ingenieur.fr/actualite/conferences-en-ligne/veille-et-intelligence-artificielle-quelles-promesses-pour-lavenir/>

27. <https://www.techniques-ingenieur.fr/actualite/articles/entreprises-intelligence-artificielle-41086/>

En plus de répondre au prosit, il est essentiel de mener une réflexion approfondie sur les différentes applications possibles de l'IA dans des domaines variés utilisant des données, ce qui est pratiquement universel. Quelques articles de référence sont fournis, et certains sujets ont déjà été abordés dans le cadre du projet Recherche & Innovation. Il n'y a pas de périmètre spécifique à l'étude.

Il est crucial de mettre l'accent sur les implications éthiques et le respect de la vie privée dans le développement et l'utilisation des technologies d'IA. La notion de "garbage in, garbage out" est particulièrement importante dans l'apprentissage machine : si les données ne sont pas correctement traitées, il est probable que des biais ou des comportements anormaux apparaissent dans les algorithmes de ML.

Il est primordial de ne pas négliger cette partie de la réflexion, car elle est essentielle pour développer des systèmes d'IA responsables et fiables.

b) Prosit Aller

i) Aide au tutorat

Prendre connaissance de la situation et la clarifier

Mots clés :

Intelligence Artificielle (IA) : Terme datant de 1956, créé par John McCarthy et défini par Marvin Lee Minsky. "La construction de programmes informatiques qui s'adonnent à des tâches qui sont, pour l'instant, accomplies de façon plus satisfaisante par des êtres humains car elles demandent des processus mentaux de haut niveau tels que : l'apprentissage perceptuel, l'organisation de la mémoire et le raisonnement critique". L'IA englobe un ensemble de concepts et techniques visant à reproduire ou à simuler l'intelligence humaine dans les machines.

Machine Learning (Apprentissage Automatique) : Champ d'étude de l'intelligence artificielle basé sur des approches mathématiques et statistiques pour donner aux ordinateurs la capacité d'apprendre à partir de données. Ce processus se divise généralement en deux phases : une phase d'apprentissage qui permet d'estimer les paramètres d'un modèle mathématique à partir d'un jeu de données, et une phase de production où de nouvelles données sont utilisées. Selon les informations contenues dans le jeu de données, l'approche peut être supervisée (le jeu de données contient les réponses à la tâche) ou non supervisée (le jeu de données ne contient pas directement les réponses à la tâche).

EDA (Analyse Descriptive des Données) : Processus permettant de résumer les caractéristiques principales d'un jeu de données souvent en utilisant des méthodes visuelles et statistiques. L'EDA aide à détecter des modèles, anomalies, tester des hypothèses, et vérifier des suppositions à l'aide de statistiques descriptives et de représentations graphiques. C'est une étape cruciale pour comprendre les données avant d'appliquer des techniques de machine learning.

Valeurs Aberrantes (Outliers) : Données qui s'écartent significativement des autres observations. Les outliers peuvent indiquer une variabilité dans une mesure, une erreur expérimentale ou une nouveauté. Ils sont identifiés et traités pour éviter d'influencer les résultats des analyses et des modèles prédictifs de manière incorrecte.

Imputation des Valeurs Manquantes : Technique utilisée pour remplacer les données manquantes dans un jeu de données. Pour les colonnes numériques, l'imputation peut se faire en utilisant la médiane ou la moyenne des valeurs présentes. Pour les colonnes catégorielles, la valeur la plus fréquente (mode) est souvent utilisée. L'imputation est essentielle pour conserver l'intégrité des analyses et éviter les biais dans les modèles de machine learning.

Contexte :

Une agence immobilière souhaite exploiter l'Intelligence Artificielle pour optimiser son activité. Il est essentiel d'explorer les applications potentielles de l'IA, en mettant l'accent sur les implications éthiques et le respect de la vie privée. La qualité des données est cruciale pour les algorithmes de machine learning, illustrant le principe de "garbage in, garbage out" : des données mal traitées peuvent introduire des biais ou des comportements anormaux dans les modèles de ML.

Analyser le besoin

Problème :

Comment s'assurer que l'algorithme de Machine Learning donne des résultats concluants ? Pour garantir la performance et l'exactitude d'un algorithme de machine learning, il est crucial de préparer adéquatement les données. Une bonne préparation des données implique le nettoyage,

le traitement des valeurs manquantes, la gestion des valeurs aberrantes, et la transformation des variables pour qu'elles soient appropriées pour l'algorithme choisi. Plus précisément, dans le contexte de ce projet, comment préparer les données des appartements afin que les analyses exploratoires et visuelles soient pertinentes et précises ?

Contraintes :

- **Données d'appartements en entrée** : Les données proviennent d'un recensement des appartements en Californie, couvrant divers aspects tels que la population, le revenu médian, et les prix des logements. Ces données doivent être correctement nettoyées et prétraitées avant d'effectuer des analyses exploratoires.

Livrables :

- **Données préparées avec justification des choix** :
 - **Nettoyage des données** : Imputation des valeurs manquantes, gestion des valeurs aberrantes.
 - **Transformation des données** : Normalisation des variables, création de nouvelles variables si nécessaire.
 - **Exploration des données** : Analyse descriptive et visuelle des données pour comprendre leurs distributions et leurs relations

Application de l'EDA et réflexion éthique :

- **Analyse exploratoire des données** : Mise en œuvre des techniques d'EDA pour comprendre les tendances et les relations dans les données des appartements.
- **Réflexion sur les applications de l'IA et les enjeux éthiques** :
 - Discussion sur les implications éthiques de l'utilisation de l'IA dans le domaine immobilier.
 - Importance du respect de la vie privée et de la gestion des biais dans les données et les algorithmes de machine learning.

Généralisation

Utilisation de l'Intelligence Artificielle

Recherche des pistes de solutions

Questions clés à se poser :

1. **Si le problème ne vient pas de l'algorithme, d'où vient-il ?**
 - Les données en entrée peuvent être une source majeure de problèmes. Il est essentiel de s'assurer que les données sont correctement préparées avant de les introduire dans l'algorithme.
2. **Comment savoir ce qu'attend l'algorithme en entrée ?**
 - Analyser les besoins de l'algorithme, la métrique utilisée pour calculer les distances entre les observations, et la méthode d'optimisation. Par exemple, pour des coordonnées géographiques (longitudes et latitudes), l'utilisation de la distance euclidienne n'est pas appropriée car elle ne prend pas en compte la courbure de la Terre. Il est préférable d'utiliser des formules géodésiques comme la distance de Haversine ou la formule de Vincenty.
3. **Comment explorer les données de manière synthétique ?**
 - Utiliser des statistiques descriptives (moyenne, médiane, écart-type, min, max) et des visualisations (boîtes à moustaches, quartiles) pour obtenir une vue d'ensemble des données.
4. **Comment formater les données pour les passer à l'algorithme ?**
 - Assurez-vous que les données sont dans un format que l'algorithme peut traiter. Cela peut inclure la normalisation, la standardisation, et la transformation des variables.
5. **Comment traiter des données non-numériques ?**

- Il est crucial de savoir si l'algorithme peut gérer des valeurs non numériques. Si ce n'est pas le cas, il faut transformer ces données en valeurs numériques de manière appropriée. Par exemple, pour des variables qualitatives ordinales (comme des niveaux de gris), il est possible de leur attribuer un ordre. En revanche, pour des couleurs de peinture, ce n'est pas toujours pertinent.

6. Comment traiter les valeurs manquantes ?

- Les valeurs manquantes peuvent contenir de l'information en soi. Il faut décider si elles peuvent être laissées vides ou doivent être imputées (par exemple, par la médiane ou le mode), en fonction de l'algorithme utilisé.

7. Comment traiter les données aberrantes (outliers) ?

- Les données aberrantes peuvent résulter d'erreurs de mesure ou être simplement des valeurs atypiques. Il est important de les détecter et de décider de la manière de les traiter pour éviter de biaiser l'algorithme.

8. Selon l'algorithme de ML employé, quels points de vigilance par rapport aux données en entrée ?

- Il est crucial de s'assurer que les données sont adaptées à l'algorithme, en vérifiant par exemple si l'algorithme accepte des données qualitatives ou quantitatives. Préparez les données de manière à ce qu'elles soient acceptables pour l'algorithme.

Applications potentielles de l'IA dans le marché immobilier :

- **Estimation des prix immobiliers** : Utilisation de modèles de régression pour prédire la valeur des biens immobiliers.
- **Analyse de tendances du marché** : Identification des tendances du marché immobilier à partir de données historiques.
- **Segmentation des clients** : Utilisation de techniques de clustering pour segmenter les clients en fonction de leurs préférences et comportements d'achat.

Considérations éthiques et respect de la vie privée :

- **Biais et équité** : Assurez-vous que les données et les algorithmes ne reproduisent pas ou n'amplifient pas les biais existants.
- **Respect de la vie privée** : Garantir que les données utilisées respectent la confidentialité et les réglementations en vigueur.
- **Transparence et explicabilité** : Les modèles d'IA doivent être explicables pour garantir une prise de décision transparente et responsable.

Concept de "Garbage In, Garbage Out" :

- Si les données en entrée ne sont pas correctement préparées et nettoyées, les résultats de l'algorithme de machine learning seront probablement biaisés ou incorrects. Il est essentiel de porter une attention particulière à la qualité des données pour obtenir des résultats fiables et significatifs.

Élaboration du plan d'actions

- **Qu'est-ce que l'Intelligence Artificielle ?**
 - Définir le concept d'Intelligence Artificielle (IA), son origine et ses principaux domaines d'application.
- **Quelles applications peut-on envisager pour le marché immobilier ?**
 - Explorer les diverses utilisations de l'IA dans le secteur immobilier, telles que la prédiction des prix, l'analyse de marché, et la segmentation des clients.
- **Quels sont les inconvénients de l'IA ?**
 - Examiner les aspects éthiques et les défis liés à l'utilisation de l'IA, y compris les biais potentiels, la confidentialité des données et la transparence des algorithmes.
- **Qu'est-ce que le Machine Learning ?**
 - Expliquer le Machine Learning (apprentissage automatique), ses principes de base, et les différences entre apprentissage supervisé et non supervisé.
- **Qu'est-ce que l'EDA (Exploratory Data Analysis) ?**

- Introduction à l'EDA, son importance dans le prétraitement des données, et les méthodes couramment utilisées pour explorer et visualiser les données.
- **Quels sont les concepts clés de la préparation des données ?**
 - Décrire les étapes essentielles du prétraitement des données pour un modèle de machine learning, notamment : a) **Traitement des données manquantes** : Imputation et gestion des valeurs manquantes. b) **Traitement des données qualitatives** : Transformation des variables catégorielles en variables numériques. c) **Transformation des données** : Normalisation, standardisation et traitement des valeurs aberrantes.
- **Examen des données (statistiques descriptives)**
 - Utiliser des statistiques descriptives pour obtenir une vue d'ensemble des données, identifier les tendances et détecter les anomalies.

c) Prosit Retour

i) Aide au tutorat


Après avoir discuté de l'IA et de ses applications, il est recommandé de faire présenter aux étudiants le pipeline de traitement de données qu'ils ont réalisé. Cela inclut les étapes d'importation des données, de gestion des valeurs manquantes, de transformation des données, et de visualisation initiale. Au fur et à mesure de leur présentation, il est important d'échanger sur leurs choix, en s'appuyant sur le code Python qu'ils ont utilisé pour comprendre et justifier leurs décisions à chaque étape du processus.

Solution

cf. définitions sur la partie « *Prendre connaissance de la situation et la clarifier* » pour les définitions d'IA et Machine Learning.

Rappels normalement concernant :

- les données = variables définies sur un domaine qui peuvent être de type quantitatives (continues ou discrète) ou qualitatives (ordinales ou non). Les variables doivent être pré-traitées en fonction des données acceptées par l'algorithme que l'on souhaite appliquer. (Exception : les algorithmes à base d'arbre de décision comme randomforest acceptent tout type de variable).



- la distribution de ces données : distribution suivant une loi normale est souvent une hypothèse de départ pour les algorithmes. Si ce n'est pas le cas, il faudra si possible transformer la variable pour qu'elle suive une distribution normale. (ex : utilisation du log pour transformer une variable suivant une distribution log normale (tail heavy) en une distribution normale)

Si le jeu de données est très grand, créer un jeu de données par échantillonnage pour son exploration peut être nécessaire.

1. Nettoyage des données

Traitement des données manquantes (algorithmes n'aiment pas les valeurs non définies en général)

- Supprimer la variable
- Remplacer par une valeur :
 - arbitraire (ex : 0 ou -1 ou 32768) : attention au biais que cela peut induire dans le traitement
 - calculée : la valeur médiane, la moyenne de cette variable ; la valeur moyenne du groupe auquel elle appartient après clustering ou encore calculée par régression par rapport à d'autres variables.

Traitement des variables qualitatives :

- S'il y a une notion d'ordre intéressante pour le métier (variable qualitative ordinale) : remplacement par valeur numérique (transformation en variable quantitative discrète) suivant cette logique d'ordre. ex : {moche, moyen, beau, très beau} -> {0, 1, 2, 3}
- S'il n'y a pas de notion d'ordre (variable qualitative nominale), le One Hot Encoding peut être employé car même s'il présente l'inconvénient de créer des variables supplémentaires à traiter par l'algorithme, il y a moins de risque d'un biais dans l'apprentissage qu'avec une notion d'ordre. ex : Statut marital {Célibataire, En couple, Marié, Divorcé, Veuf/Veuve} il vaut mieux créer 5 variables binaires représentant chacune des valeurs (plutôt qu'un code : du style 0 = célibataire et 5 = veuf qui pourrait induire un biais dans l'apprentissage : distance divorcé/célibataire plus grande que divorcé/marié avec cette logique).
- Il est possible aussi pour les données qualitative discrètes nominales d'utiliser une hiérarchie de concepts pour réduire le nombre de valeurs. ex : adresse > ville > région > pays (ex : dans les données du prosit, on travaille avec le salaire médian).

Traitement des variables quantitatives :

Certains algorithmes ne sont capable de traiter que des variables quantitatives discrètes ou qualitatives. Dans ce cas, il sera nécessaire de discrétiser les valeurs de la variable quantitative continue. L'histogramme, le clustering sont des exemple d'approches permettant d'opérer cette discrétisation.

Traitement des données aberrantes :

Grâce aux calculs de moyenne et écart-type ou encore en traçant des boîtes à moustache ou les nuages de points, des variables prises 2 à 2, on peut parfois observer des données aberrantes car très éloignées des valeurs classiquement mesurées. Dans ce cas il convient d'enquêter sur son origine et si cela est avéré, de supprimer la valeur du jeu de données soit en supprimant l'observation entière soit en remplaçant sa valeur par une autre calculée (max des autres valeurs par exemple -> on parle de capping des données). (Des valeurs mal choisies peuvent avoir un impact sur la distribution observée des données, cf. median_house_value qui a subit ce traitement dans le jeu de données du prosit.

2. Intégration

On peut avoir des données issues de sources différentes où issues d'un modèle de données qu'on va devoir intégrer pour pouvoir traiter l'ensemble en tant que jeu de données.

Ce n'est pas couvert dans le WS mais ils auront besoin de cette approche pour intégrer le modèle de données du projet (équivalent d'une jointure sur le champ EmployeeID) :

```
#merging all the data frames
```

```
attrition_data<-merge(employee_survey_data,manager_survey_data,by="EmployeeID",all=F)
```

Si ce sont des données issues de source différentes, il faudra peut être traiter les doublons ou des différences dans le nom des variables (synonymes) voir des noms de variable identiques pour des données différentes...

3. Transformation

- Selon le contexte métier : il peut être intéressant de transformer certaines variables (ex du WS : le nombre de personnes par ménage finalement est plus important que le nombre de personnes dans le quartier et nombre de ménages dans le quartier pour qualifier le quartier dans le cadre de l'étude du prix de l'immobilier.

- Selon la distribution des valeurs des variables : beaucoup d'algorithmes partent de l'hypothèse d'une distribution des valeurs suivant une loi normale, si ce n'est pas le cas et si c'est possible, transformer la variable pour que sa distribution soit plus proche d'une distribution normale est

important. L'exemple classique est le cas des variables dont la distribution est "heavy-tail" qui correspond plus à une distribution log-normale : en prenant le log de la valeur initiale, la nouvelle variable créée a une distribution plus proche de la loi normale (Gaussienne).

- Selon les différences d'échelle entre les variables du jeu de donnée : quand on mesure la distance entre 2 observations si une variable est sur une échelle allant de 0,1 à 0,5 quand l'autre est sur une échelle allant de 10000 à 50000, on sent bien que la 2ème variable aura un poids plus important sur cette mesure de distance. Il en est de même pour une variable plus étalée sur son domaine de définition qu'une autre. Il existe plusieurs approches pour pallier à ce problème :

- La mise à l'échelle (linear scaling ou min-max scaling) : $x' = (x - x_{min}) / (x_{max} - x_{min})$ (Attention cette approche est sensible aux valeurs aberrantes et suppose une distribution uniformément répartie).

- Le clipping ou capping (cf. partie traitement des données aberrantes).

- Le log-scaling : $x' = \log(x)$ (cf. point précédent).

- Le Z-Score : $x' = \frac{x - \mu}{\sigma}$ où μ désigne la moyenne et σ l'écart-type de la variable. Suppose que la distribution de la variable suit la loi normale. L'échelle ne sera pas exactement la même entre les variables car dépendant de leur écart-type contrairement à la mise à l'échelle.

4. Réduction

Réduction du nombre d'attributs pour ne retenir que ceux pertinents à première vue (beaucoup d'algorithmes ont pour hypothèse que les variables sont indépendantes, garder 2 variables très corrélées leur donne un poids plus important dans le processus d'apprentissage).

Réduire le nombre d'observations dans le jeu de données par un échantillonnage :

Tout ceci aussi afin de garantir un temps d'exécution raisonnable de l'algorithme de machine learning.

Garder un échantillon du jeu de données pour valider les modèles appris est très important dans le processus -> prosit suivant...

Conclusion

On va devoir préparer nos données de manière à ce que chaque attribut soit à peu près sur la même plage de valeur pour ne pas donner plus de poids à l'un plutôt qu'un autre (min-max scaling ou Z-score).

De même, un échantillonnage stratifié peut aider à l'apprentissage si on sait que dans ce jeu de données ou cette population, certaines catégories d'observations déjà identifiées sont sur ou sous représentées (ex : un groupe surreprésenté peut conduire à un apprentissage d'une classe représentant un sous groupe de cette classe surreprésentées plutôt qu'une classe représentant une minorité).

2. Workshop du prosit 1

2.1. Sujet

a) Énoncé

i) Exercice

Le WS prend la forme d'un notebook Jupyter à compléter ainsi que son jeu de données. N'hésitez pas à le commencer avant son animation de manière à pouvoir poser des questions précises à votre intervenant qui pourraient servir aussi pour le projet :

(cf. WS_Exploratory_Data_Analysis_Etudiant.ipynb)

(cf. housing.tgz)

2.2. Guide pédagogique

a) Corrigés-types

(cf. WS_Exploratory_Data_Analysis_Version_Tuteur.ipynb)

1. 2-Boucle PBL

Objectifs d'apprentissage

Régression linéaire et non linéaire

[1] Identifier une tâche de régression à partir d'un jeu de données ou d'une application réelle

[1] Lister les différents types de régression linéaire (simple, multiple) et non linéaire (polynomiale, par noyau, etc.).

Apprentissage supervisé : Régression

[5] Estimer la pertinence et l'efficacité des modèles développés pour résoudre les tâches assignées

[6] Proposer des améliorations pour les modèles de régression linéaire et non-linéaire en fonction des résultats obtenus et des analyses de résidus

[2] Citer des modèles développés pour résoudre les tâches assignées

[4] Analyser les performances des modèles de régression en utilisant des métriques telles que le coefficient de détermination (R^2) et l'erreur quadratique moyenne (MSE)

1.1. Sujet

a) Questions/réponses

Un forum appelé « Questions aux experts » est proposé à l'issue de cette boucle PBL. Des experts CESI seront disponibles pour répondre à vos interrogations.

Veuillez noter que vous ne devez pas vous attendre à une réponse immédiate à vos questions. Les intervenants du forum se connecteront à certains moments uniquement pour répondre aux questions, en fonction de leur emploi du temps.

Il est important de comprendre que le forum n'est pas destiné à fournir des réponses directes aux sujets des boucles PBL ou du projet. Son objectif est plutôt de fournir des éclaircissements et des ressources complémentaires pour vous aider à mieux comprendre les concepts abordés.

b) Énoncé

i) Exercice : Prédictions immobilières

Nous avons fait d'importants progrès dans notre traitement des données. Maintenant, il est crucial d'exploiter pleinement tous les outils à notre disposition pour optimiser le fonctionnement de notre société immobilière.

Comme pour toute entreprise en relation avec ses clients, l'exactitude des prix proposés est une préoccupation majeure. Nous sommes désormais convaincus que notre dispositif sera capable de prédire le prix de chaque bien que nous ajoutons à notre catalogue, en utilisant les informations dont nous disposons déjà, telles que la taille de la maison, l'âge médian des logements, le nombre de chambres, et la proximité de l'océan.

L'expert en IA que nous avons recruté a déjà établi une stratégie pour résoudre ce problème : il s'agit de modéliser le prix médian des logements d'un block group en fonction de tous les autres attributs, en utilisant des modèles de régression. Par exemple, en prenant en compte des variables telles que la latitude, la longitude, le revenu médian des foyers, et la population, nous pouvons ajuster notre modèle pour prédire le prix avec une grande précision.

Je fais confiance en son expertise, mais il reste encore à déterminer les différents paramètres du modèle. Des ajustements comme le choix des variables et la régularisation doivent être optimisés pour assurer que notre modèle ne sur-apprenne pas, c'est-à-dire qu'il ne s'adapte pas trop étroitement aux données d'entraînement au point de perdre sa capacité à généraliser sur de nouvelles données.

Même si cela semble être une tâche réalisable, nous avons été avertis des défis liés à la validité de la solution proposée et au risque de sur-apprentissage. Pour cela, nous utiliserons, peut être, des techniques telles que la validation croisée pour évaluer la performance du modèle et détecter tout signe de sur-apprentissage. Des indicateurs de qualité comme le coefficient de détermination (R^2) et l'erreur quadratique moyenne (MSE) seront essentiels pour permettre l'amélioration continue du modèle si nécessaire.

Le protocole est en marche, et nous avons identifié tous les points de vigilance, à commencer par les erreurs à ne pas reproduire. Nous allons commencer par bien préparer nos données : nettoyer les valeurs manquantes, traiter les données aberrantes, et normaliser les variables pour assurer une entrée cohérente dans l'algorithme. Une fois que tout sera prêt, il ne nous restera plus qu'à industrialiser le processus, en automatisant les étapes pour garantir une efficacité et une précision maximales dans nos prédictions de prix immobiliers.

c) Ressources pour les étudiants

Pipeline ML

Conférence ; Pipeline Machine Learning - M. A. Benatia²⁸

Supports : *PipelineML_BENATIA* (cf. *PipelineML_BENATIA.pdf*)

Ressources principales avec mise en application

Partie 1 - Descente de gradient (cf. *Partie 1 - Descente de gradient.zip*) : comprendre les concepts mathématiques importants

Partie 2 - Linear Regression (cf. *Partie 2 - Linear Regression.zip*): comprendre la régression linéaire

Ouvrages de référence

Python Data Science Handbook, Jake VanderPlas²⁹

Scikit-learn³⁰

1.2. Guide pédagogique

a) Aide au tutorat

Philosophie du prosit

Nous cherchons ici à réaliser une régression linéaire sans fournir directement l'information (modélisation du prix médian des logements d'un block group en fonction de l'ensemble des autres attributs). Cependant, il est mentionné la méthode de résolution et les paramètres. Il convient de réfléchir à ces termes s'ils ne sont pas familiers pour les étudiants.

Le contenu de ce propos est ambitieux (propos + ressources avec application + WS), il est donc important de les encourager à s'y plonger intensément afin de mieux comprendre la suite et d'être plus efficaces dans le projet.

Le WS les guide vers la solution du propos, mais les ressources avec applications sont également essentielles pour saisir les concepts sous-jacents.

Pas de fausse piste.

Notes au tuteur, conseils, trucs et astuces

Ce prosit doit avoir une dimension mathématiques. Le plan d'action doit incorporer l'étude de cet aspect mathématiques avec pour objectif de comprendre ce qui est réalisé ici.

²⁸. https://www.youtube.com/watch?v=WFT_NxzixSY&feature=youtu.be

²⁹. <https://jakevdp.github.io/PythonDataScienceHandbook/>

³⁰. <https://scikit-learn.org>

b) Prosit Aller

i) Aide au tutorat**Prendre connaissance de la situation et la clarifier***Mots clés :*

stratégie (d'exploration)

Régression Linéaire Simple (Méthode des moindres carrées)

Régression avec des modèles avancés (DTree, KNN, SVM)

fonction de coût (MSE)

sur-apprentissage

Contexte :

Après les premiers pas avec l'I.A., notre agence immobilière souhaite continuer l'aventure pour ajuster les prix proposés aux clients.

Analyser le besoin*Problème :*

Comment estimer efficacement le prix médian des logements ?

Contraintes :

Utiliser la méthode des moindres carrées

Calculer l'erreur MSE

Ajuster les poids d'un modèle

Données

Livrables :

Régression linéaire avec une fonction de coût déterminée. Idéalement une validation des choix.

Généralisation

Prédiction de données

Recherche des pistes de solution

A quoi correspond la stratégie mentionnée dans le sujet ?

Que vous inspire "fonction de coût" ?

Que représente une régression linéaire ?

Quelle approche est proposée dans le sujet ?

Quelle différence y a-t-il entre le problème du prosit précédent et celui-ci ?

Pouvez-vous exprimer "visuellement" la stratégie visée ?

N'y a-t-il qu'une seule stratégie ?

Comment déterminer la fonction de coût ?

Comment savez-vous que la prédiction faite est la bonne ?

Pouvez-vous "vérifier" vos choix ?

Élaboration du plan d'actions

1. Algorithme "intelligent" permettant une prédiction de donnée

2. Exploitation des données pour "apprendre"

3. Principe de la stratégie ?

4. Fonction de coût ?

6. Algorithme final (régression linéaire)

7. Préparation des données
8. [Idéalement] Validation des choix
9. Industrialisation (Pipeline)

c) Prosit Retour

i) Aide au tutorat

Définitions

Voici l'approche du prosit, ce que les élèves doivent avoir compris au minimum :

Problème : Je souhaite modéliser le prix médian d'une maison d'un quartier en fonction des données que j'ai concernant l'ensemble de quartiers (block group).

Données d'entrées : Les données préparées (fin de du WS du prosit précédent).

Hypothèse : Variation linéaire du prix en fonction des différents attributs (super important qu'ils arrivent à ces réflexions en prosit aller : plus la maison est près de l'eau, plus elle va être chère en général, plus les revenus du ménage sont importants, plus ils vont acheter une maison chère. Plus la famille est grande, plus la maison achetée sera chère)

Cette hypothèse nous amène à la construction d'un modèle :

y (le prix médian d'une maison) = $w_0 + w_1 \times x_1 + w_2 \times x_2 + \dots + w_n \times x_n$ (modèle linéaire : pour une simple variable x : $y = ax + b$)

où $\vec{x}$ correspond à une observation et $\vec{w}$ correspond au poids associé à chaque attribut de l'observation permettant ainsi d'estimer le prix médian d'une maison (y) à partir des attributs observés dans les différentes observations du jeu de données.

Comment définir les valeurs du vecteur $\vec{w}$ à partir de l'ensemble des observations ?

On a des approches de résolution exactes mais sur de grands jeux de données avec beaucoup d'attributs et/ou beaucoup d'observation et du bruit (imprécision ou doublons dans les mesures par exemple), elles ne sont pas efficaces (en temps mais aussi si j'apprends sur un jeu de données, est-ce que je peux généraliser à un autres ?).

C'est là que le principe de la descente du gradient entre en jeu avec un apprentissage supervisé : je connais des prix médians pour n exemples de quartiers sur lesquels je vais baser mon apprentissage.

On va pouvoir définir des valeurs pour mon vecteur $\vec{w}$ et définir une fonction objectif qui va permettre d'identifier en quelle mesure ce vecteur est efficace pour estimer le prix médian d'une maison (y) connaissant vraiment le prix médian d'une maison $\hat{y}$ pour une observation donnée $\vec{x}$.

On peut envisager plusieurs fonctions objectifs :

- MSE : $MSE = \frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2$ où n est le nombre d'observations dans mon jeu de données d'entraînement.
- RMSE : $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2}$ où n est le nombre d'observations dans mon jeu de données d'entraînement.

Plus ces valeurs sont proches de 0, plus les y , estimés grâce à $\vec{w}$ sont proches de $\hat{y}$, les valeurs connues dans l'échantillon d'entraînement.

Pour explorer, l'espace des valeurs que peut prendre $\vec{w}$, la stratégie de la descente du gradient pourra être exploitée avec des paramètres importants : le taux d'apprentissage α (learning rate) et le nombre d'itérations (epochs) sur le jeu de données.

La ressource "Descente de gradient" détaille les concepts mathématiques liés à cette partie et le WS son usage concret avec ScikitLearn.

Très grossièrement, cette approche va permettre d'explorer le domaine de définition du vecteur $\vec{w}$ en le modifiant (selon le taux d'apprentissage défini) d'une itération à l'autre de manière à minimiser la fonction objectif.

Dans le cas idéal où les distributions des différents attributs suivraient toutes une loi normale, les fonctions objectifs définies ci-dessus seront bien des fonctions convexes et on pourrait atteindre un minimum globale. Dans la réalité, ce n'est pas forcément le cas et il peut y avoir des minimums locaux, l'approche de la descente du gradient ne nous garantie donc pas d'atteindre un minimum global mais « *une bonne préparation des données* » et des choix judicieux de paramètres contribuent à s'en approcher.

On peut chercher à mesurer la qualité du résultat obtenu au final en confrontant le modèle obtenu en sortie de la descente de gradient à un jeu de test, c'est à dire un jeu de données dont on connaît la sortie qui n'a pas été utilisé pour l'entraînement du modèle. Ainsi un MSE sur le jeu de test > au MSE obtenu sur le jeu d'entraînement peut être un indicateur de sur-apprentissage et un MSE élevé en général un indicateur de sous-apprentissage.

Solution

cf. correction du WS

2. Workshop du prosit 2

2.1. Sujet

a) Énoncé

i) Exercice

Le WS prend la forme d'un notebook Jupyter à compléter du même style (c'est la suite) que le notebook proposé sur le prosit précédent.

(cf. WS_Regression.ipynb)

2.2. Guide pédagogique

a) Corrigés-types

Notebooks Jupyter du WS. Le premier est la version tuteur.

(cf. WS_Regression_Analysis_Tuteur.ipynb)

Boucle IA pour la classification supervisée

VI

1. 3-Boucle PBL

Objectifs d'apprentissage

[3] Appliquer des approches supervisées de classification pour prédire des catégories à partir de données annotées.

[1] Lister les différents algorithmes de classification utilisés en machine learning.

[4] Expliquer les principes de base des algorithmes de classification supervisée (e.g., k-NN, arbres de décision, SVM).

[4] Analyser les performances des modèles de classification supervisée à l'aide de métriques telles que la précision, le rappel, la F1-score et l'AUC.

[6] Combiner plusieurs techniques de prétraitement et d'algorithmes pour optimiser les résultats de classification supervisée.

[5] Utiliser la régression logistique pour prédire la probabilité d'un événement binaire, comme la vente d'un bien immobilier dans un délai donné.

[2] Définir les concepts de classification et en comprendre les principes de fonctionnement.

1.1. Sujet

a) Énoncé

i) Exercice : La classe !

Situation Actuelle

Tout se déroule comme prévu pour le moment ! Les résultats semblent prometteurs et si nous continuons ainsi, la pérennité de l'entreprise est assurée. Cependant, nous avons encore un objectif crucial à atteindre pour garantir notre succès à long terme.

La dernière étape de notre plan consiste à estimer le potentiel de vente de nos biens immobiliers. Cela nous permettra de faire des projections financières les plus précises possibles pour les prochains mois. Nous devons savoir, avec un haut niveau de confiance, si un bien sera vendu dans les 6 mois.

Nouvelle donnée

Heureusement, nous avons conservé toutes nos données de ventes passées. Ces informations sont précieuses et vont nous permettre de créer des modèles prédictifs fiables. Nous avons récemment ajouté un nouvel élément aux données du recensement : un attribut booléen nommé "Sold6M", défini à 1 si 80 % des biens gérés par l'agence dans un quartier ont été vendus dans les 6 mois, et à 0 sinon. Cette nouvelle donnée est essentielle pour notre analyse.

Étant donné que nous évoluons dans le domaine financier, notre service en charge des projections est particulièrement exigeant en termes de garanties. Ils ont expressément demandé une validation rigoureuse du modèle, reposant sur des indicateurs de qualité pertinents. Nous devons nous assurer que notre modèle est non seulement précis, mais aussi fiable et robuste.

Réflexion et Stratégie

En réfléchissant à la meilleure approche pour garantir la qualité de notre modèle, vous vous rappelez une expérience de votre précédent emploi dans une maison de disques. Vous aviez participé à une enquête sur les ventes d'albums en utilisant deux approches, une appelée "Perceptron" et l'autre « Decision Trees ». À l'époque, vous ne saviez pas exactement ce que c'était, mais vous saviez que c'était des méthodes efficaces pour des prédictions de valeurs booléennes.

Vous avez donc soumis l'idée à notre expert en IA, et il a confirmé que cela pourrait fonctionner. Il a dit : "Si une simple régression ne suffit pas, il est vrai qu'un Perceptron pourrait nous aider." Cette approbation renforce notre confiance dans cette approche. Il semble que nous soyons sur la bonne voie pour créer un modèle prédictif puissant.

Enfin, quelques questions restent sans réponse, notamment pour l'Interprétation et la discussion des résultats.

1. Performance du Modèle :

- Comment les différents modèles se comparent-ils en termes de performance dans le cadre de la classification supervisée ? Pouvons-nous utiliser la MSE ? Le Perceptron a-t-il apporté une amélioration significative par rapport à la régression de la boucle 2 ?
- Quels indicateurs de qualité utilisez-vous pour valider la performance du modèle et pourquoi ?

2. Impact des Variables :

- Quels sont les attributs les plus influents dans la prédiction de la vente des biens dans les 6 mois ? Comment pouvez-vous utiliser ces informations pour améliorer vos stratégies de vente ?

3. Limites et Améliorations :

- Quelles sont les limitations potentielles des modèles utilisés ? Comment pourriez-vous améliorer ces modèles à l'avenir ? Considérez les aspects de la qualité des données, de l'ingénierie des caractéristiques et de l'optimisation des hyperparamètres.

b) Ressources pour les étudiants

Ressources

Vidéo d'introduction à la régression logistique et au perceptron³¹

Conférence M. A. Benatia : Machine Learning : Classification³²

Support conférence : *MLClassification_BENATIA.pdf* (cf. *MLClassification_BENATIA.pdf*)

Documentation Scikit-Learn : Perceptron³³

Documentation Scikit-Learn : Regression Logistique³⁴

Ouvrage de référence

Python Data Science Handbook, Jake VanderPlas³⁵

Pour aller plus loin (Techniques de l'ingénieur)

Apprentissage statistique supervisé³⁶

Régulation par réseaux de neurones³⁷

c) Livrables attendus

Le jeu de données :

(cf. *housing6month.zip*)

1.2. Guide pédagogique

a) Aide au tutorat

Philosophie du prosit

³¹. <https://www.youtube.com/watch?v=jbluHlgBmBo>

³². https://youtu.be/ow_TNi1esyw

³³. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Perceptron.html

³⁴. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

³⁵. <https://jakevdp.github.io/PythonDataScienceHandbook/>

³⁶. <https://www.techniques-ingenieur.fr/base-documentaire/innovation-th10/innovations-en-electronique-et-tic-42257210/apprentissage-statistique-supervise-h5010/>

³⁷. <https://www.techniques-ingenieur.fr/base-documentaire/automatique-robotique-th16/automatique-avancee-42393210/regulation-d-un-processus-industriel-par-reseaux-de-neurones-s7582/>

Pour continuer les manipulations réalisées dans les prosits précédents, nous allons maintenant nous focaliser sur la classification. L'objectif est de proposer un modèle de classification en veillant à bien intégrer une étape de validation obligatoire. Cette validation a probablement été abordée dans le prosit précédent. Si ce n'est pas le cas, il est crucial de bien la souligner ici.

Importance de l'Étape de Validation

L'étape de validation est essentielle pour s'assurer que le modèle de classification fonctionne correctement et qu'il sera capable de généraliser sur de nouvelles données. Elle permet de mesurer la performance du modèle et de détecter les éventuels problèmes de surapprentissage (overfitting). Voici les étapes clés à suivre pour la validation :

1. **Séparation des Données** : Divisez votre jeu de données en deux parties : un ensemble d'entraînement (training set) et un ensemble de test (test set). Généralement, une répartition de 80/20 ou 70/30 est utilisée.
2. **Entraînement du Modèle** : Utilisez l'ensemble d'entraînement pour ajuster les paramètres du modèle de classification. Cela implique de passer les données à travers l'algorithme de classification pour qu'il puisse apprendre les relations entre les variables.
3. **Validation Croisée (Cross-Validation)** : Utilisez la validation croisée pour évaluer la performance du modèle. La validation croisée k-fold est couramment utilisée, où les données d'entraînement sont divisées en k sous-ensembles. Le modèle est entraîné k fois, chaque fois en utilisant k-1 sous-ensembles pour l'entraînement et le sous-ensemble restant pour la validation. Les résultats sont ensuite moyennés pour obtenir une estimation plus robuste de la performance du modèle.
4. **Évaluation sur l'Ensemble de Test** : Après avoir sélectionné le modèle optimal à l'aide de la validation croisée, évaluez-le sur l'ensemble de test. Cela permet d'obtenir une estimation de la performance du modèle sur des données non vues.
5. **Mesures de Performance** : Utilisez des métriques telles que la précision (accuracy), la précision (precision), le rappel (recall), le score F1 et l'AUC-ROC pour évaluer la performance du modèle. Ces métriques fournissent une vue d'ensemble des capacités du modèle à classer correctement les données.
6. **Analyse des Résultats** : Interprétez les résultats pour comprendre les points forts et les faiblesses du modèle. Identifiez les domaines où le modèle peut être amélioré, que ce soit par un ajustement des hyperparamètres, l'ajout de nouvelles fonctionnalités ou l'utilisation d'un modèle de classification différent.

Le Perceptron :

Le Perceptron est mentionné dans le sujet pour établir un lien avec le bloc Perceptron étudié précédemment. Le Perceptron est un algorithme de classification binaire simple qui peut être utilisé comme point de départ pour comprendre les concepts de base de la classification. Il est souvent utilisé pour illustrer les principes fondamentaux de l'apprentissage supervisé et des réseaux de neurones.

En résumé, l'étape de validation est une phase cruciale dans la construction d'un modèle de classification fiable et généralisable. Elle permet de s'assurer que le modèle fonctionne bien sur des données nouvelles et de prévenir les problèmes de surapprentissage. En mettant l'accent sur cette étape, nous incitons les élèves à s'intéresser à la robustesse et la fiabilité des prédictions faites par le modèle.

Pas fausse piste.

Notes au tuteur, conseils, trucs et astuces

b) Prosit Aller

i) Aide au tutorat

Prendre connaissance de la situation et la clarifier

Mots clés :

- Validation du modèle
- Perceptron
- Régression logistique
- Classification binaire

- Cross-validation
- Surapprentissage

Contexte :

Pour aller plus loin, l'agence immobilière souhaite maintenant classer ses informations en deux catégories distinctes : les biens qui seront vendus dans les 6 mois et ceux qui ne le seront pas. En se basant sur les ventes précédentes, l'agence cherche à prédire cette classification afin d'optimiser ses stratégies de vente et de marketing.

Dans cette optique, nous allons explorer l'utilisation de modèles de classification, en mettant un accent particulier sur la validation des modèles pour garantir leur efficacité et leur fiabilité. Le Perceptron, déjà étudié dans le cadre du bloc Perceptron, ainsi que d'autres méthodes comme la régression logistique, seront utilisés pour effectuer cette tâche. La validation croisée sera intégrée pour s'assurer que les modèles généralisent bien sur des données nouvelles, évitant ainsi les problèmes de surapprentissage.

Analyser le besoin

Problème :

Comment réaliser une classification supervisée fiable et efficace ?

Contraintes :

- **Données** : Utilisation des données de ventes précédentes pour l'entraînement du modèle.
- **Modèles** : Possibilité d'utiliser un Perceptron et/ou une régression logistique pour effectuer la classification.
- **Validation** : Validation obligatoire du modèle proposé pour s'assurer de sa performance et de sa capacité à généraliser.

Livrables :

- **Algorithme de classification** : Implémentation d'un modèle de classification supervisée.
- **Validation du modèle** : Évaluation du modèle en utilisant des métriques pertinentes (ex. : précision, rappel, F1-score, AUC) pour garantir sa fiabilité et son efficacité.

Généralisation

Utilisation de l'I.A. pour résoudre une tâche de classification binaire

Recherche des pistes de solution

- **Catégorisation des données** : Comment déterminer l'assignation des données à l'une des deux catégories recherchées ? Quels critères ou algorithmes utiliser pour optimiser cette assignation ?
- **Régression linéaire vs régression logistique** : Quelles sont les différences fondamentales entre une régression linéaire et une régression logistique ? Dans quels cas utiliserait-on l'une plutôt que l'autre ?
- **Fonctionnement du Perceptron** : Pouvez-vous rappeler le principe de fonctionnement du Perceptron ? Comment ce modèle peut-il être appliqué à notre problème de classification binaire ?
- **Complexité des algorithmes** : Pourquoi est-il nécessaire d'utiliser un algorithme complexe pour classer les données en deux catégories ? Quels sont les avantages d'un modèle sophistiqué par rapport à une approche plus simple ?
- **Validation du modèle** : Qu'est-ce que la validation d'un modèle ? Pourquoi est-elle cruciale dans le cadre de la classification supervisée ? Quelles méthodes de validation pouvons-nous utiliser pour nous assurer de la performance du modèle (ex. : validation croisée, jeu de test, métriques d'évaluation) ?
- **Lien avec le prosit précédent** : Comment les travaux réalisés dans le prosit précédent peuvent-ils être exploités pour cette nouvelle tâche de classification ? Quelles compétences et connaissances acquises auparavant peuvent être réutilisées ici ?
- **Critères de performance** : Quels critères de performance sont les plus pertinents pour évaluer un modèle de classification dans ce contexte ? Comment ces critères influencent-ils le choix du modèle final ?

- **Impact des données** : Comment les caractéristiques des données (ex. : déséquilibre des classes, qualité des données, présence de bruit) affectent-elles le processus de classification ? Quels prétraitements peuvent être nécessaires pour améliorer la performance du modèle ?

Élaboration du plan d'actions

1. Compréhension du Contexte et des Données

- **Analyse des besoins** : Revoir les objectifs de l'agence en matière de classification des biens.
- **Description des données** : Étudier les attributs du dataset et comprendre leur pertinence pour la tâche de classification.

2. Préparation des Données

- **Nettoyage des données** : Identifier et traiter les valeurs manquantes, les anomalies et les données aberrantes.
- **Transformation des données** : Normaliser et standardiser les attributs numériques, encoder les attributs catégoriels.
- **Ajout de la nouvelle colonne** : Générer et ajouter la colonne "Sold6M" pour chaque quartier en fonction des ventes passées.

3. Exploration et Visualisation des Données

- **Analyse exploratoire** : Utiliser des graphiques et des statistiques descriptives pour comprendre la distribution des données.
- **Visualisation des relations** : Créer des visualisations pour explorer les relations entre les attributs et la variable cible "Sold6M".

4. Développement du Modèle de Classification

- **Sélection des modèles** : Choisir les modèles de classification à tester (Perceptron, régression logistique, SVM, KNN, Naive Bayes, etc.).
- **Implémentation des modèles** : Utiliser des bibliothèques comme scikit-learn pour implémenter les modèles choisis.

5. Validation et Évaluation du Modèle

- **Partitionnement des données** : Diviser le dataset en jeux d'entraînement et de test.
- **Validation croisée** : Utiliser la validation croisée pour évaluer la performance des modèles.
- **Métriques d'évaluation** : Calculer les métriques telles que l'accuracy, la précision, le rappel, et le score F1 pour chaque modèle.
- **Sélection du meilleur modèle** : Comparer les performances des modèles et sélectionner celui qui offre les meilleurs résultats.

6. Interprétation des Résultats

- **Analyse des coefficients** : Examiner les coefficients des modèles pour comprendre l'importance des différents attributs.
- **Discussion des performances** : Analyser les résultats obtenus et discuter des forces et faiblesses de chaque modèle.

7. Optimisation et Amélioration

- **Ajustement des hyperparamètres** : Utiliser des techniques de recherche d'hyperparamètres pour optimiser les modèles.
- **Itération sur les modèles** : Réentraîner les modèles avec les meilleurs hyperparamètres et vérifier les améliorations.

c) Prosit Retour

i) Approche globale

Dans les données, une donnée a été ajoutée, l'attribut Sold6M qui est binaire. Il nous permettra de passer de la régression linéaire du prosit précédent à une régression logistique.

Comme la régression linéaire permet de générer un modèle linéaire prédisant une valeur en sortie (le prix de vente médian des maisons du quartier) à partir de l'ensemble des paramètres, la régression logistique permet de générer un modèle prédisant une sortie binaire (le bien est vendu dans les 6 mois ou non) à partir de l'ensemble des paramètres.

Pour l'agence cela signifierait qu'elle pourrait prédire pour un nouveau bien entrant s'il sera vendu rapidement ou non.

Au niveau métier, certains attributs ne seront pas accessibles à l'agence à l'arrivée d'un nouveau bien comme par exemple le salaire médian ou la taille de la famille. La meilleure des approches serait de générer les données manquantes à partir de régressions telles que celle du proxit précédent.

Ces informations permettront à l'agence de cibler la clientèle pour ce nouveau bien (cela sous entend des quartiers homogènes en termes d'offres de logement).

L'approche globale ressemble beaucoup à ce qui a été fait pour la régression linéaire (on considère que le travail exploratoire sur les données a été effectué) tant que l'on reste dans de l'apprentissage supervisé :

- Création du jeu de test et du jeu d'entraînement (cf. WS ; si jeu de données très important, génération aussi un jeu de données pour l'exploration)
- Préparation des données en créant le pipeline de transformation.
- Choisir et entraîner un modèle (choix de la fonction objectif, dont il faudra minimiser le résultat : moindres carrés (SCR), moyenne des carrés des erreurs (MSE) ou racine des écarts à la moyenne (RMSE) ou maximum de vraisemblance par exemple)
- Évaluer/valider un modèle (résultat avec métrique comme RMSE sur jeu de données d'entraînement complet) ou possibilité d'utiliser la validation croisée (le jeu d'entraînement est divisé en k sous-jeux. Chacun de ces sous-jeux est utilisé pour évaluer le modèle avec une métrique comme RMSE suite à un entraînement sur les $k-1$ autres sous-jeux. Ceci permet de constater (notamment via l'écart-type de ce tableau de k scores) s'il y a tendance à du sur-apprentissage avec les hyper-paramètres choisis. En cas de sur ou sous-apprentissage, on peut repartir au point précédent en modifiant les hyper-paramètres jusqu'à obtenir satisfaction.
- Évaluer le modèle sur le jeu de test avec un score tel que le RMSE (plus petit = meilleur) (on peut effectuer cette démarche en s'appuyant sur des modèles différents (linéaire, polynomial, Random Forest...) en adaptant le pipeline de transformation si nécessaire par rapport à son fonctionnement). On peut aussi comparer les résultats de différentes approches pour choisir celle donnant les meilleurs résultats (si la métrique choisie est RMSE, l'approche donnant le plus petit score sera la meilleure).
- Assurer la mise en production en intégrant les sources de données, ajoutant des tests, des métriques de monitoring de la performance, de suivi de la qualité des données en entrée et enfin automatiser la sauvegarde des modèles précédents (backup) et la mise à jour du modèle (re-fit).

En classification, ce qui va changer c'est que le modèle choisi ne sera pas une régression mais un algorithme de classification supervisée.

Classification binaire


La régression logistique est le moyen le plus simple de comprendre la classification binaire après avoir fait la régression linéaire. En effet, au lieu d'estimer une droite (si 2 attributs seulement, un hyperplan si on généralise à plus d'attributs) représentant notre nuage de points avec le minimum d'erreur, on va estimer une droite qui va séparer au mieux les nuages de point représentant chaque classe.

La régression logistique repose sur le modèle suivant :


$$\ln\left(\frac{p(1|X)}{1-p(1|X)}\right) = w_0 + w_1x_1 + w_2x_2 + \dots + w_Jx_J$$

(nommé LOGIT de $p(1|X)$) où $p(1|X)$ correspond à la probabilité d'être dans la classe 1 connaissant les variables prédictives (attributs), $x_1, x_2, \dots, x_J$

correspondent à une observation et $w_0, w_1, \dots, w_J$ correspondent aux poids que l'on va devoir estimer grâce à notre jeu de données d'entraînement. Il s'agit bien d'une régression car on modélise une dépendance entre la variable à expliquer et les variables explicatives.



En transformant l'équation sous cette forme : $p(1|X) = \frac{e^{w_0 + w_1 x_1 + w_2 x_2 + \dots + w_J x_J}}{1 + e^{w_0 + w_1 x_1 + w_2 x_2 + \dots + w_J x_J}}$, il peut être constaté que la densité de probabilité $p(1|X)$ suit une loi logistique. Ici classifier revient à estimer la probabilité d'appartenance à la classe 1. Sa fonction de répartition est une fonction logistique particulière, une sigmoïde (dont la dérivée est simple à calculer -> pratique pour la descente de gradient et dont le point d'inflexion est à la valeur 0,5).



L'approche de la descente du gradient peut être utilisée comme pour la régression linéaire pour estimer les poids w .

Quand le nombre d'attributs devient très élevé, l'utilisation l'approche de la descente de gradient stochastique est employée en générale (approche proposée dans le WS).

Concernant les algos, la vidéo en ressource explique les choses de manière très abordable et visuelle. Dans Scikit-Learn, plusieurs algos sont proposés : la régression logistique et le perceptron en font partie.

```
1 from sklearn.linear_model import SGDClassifier # Descente de gradient Stochastique
2 sgd_clf = SGDClassifier(max_iter=5, random_state=42, loss='log') # regression
   logistique sur cet exemple, loss='perceptron' pour le perceptron
3 sgd_clf.fit(X_train, y_train_5) #SOLUTION # Entraînement du modèle
```

Perceptron Algorithm : Optimization problem

□ Define the loss function

$$L(z, y_i) = \begin{cases} 0 & \text{if } y_i z \geq 0, \text{ and} \\ -y_i z & \text{Otherwise} \end{cases}$$

□ Here, z is the classifier's prediction, y_i is the correct answer

- If z has the same *sign* as y_i , the loss function is zero
- But, if z has the wrong sign the loss function is positive

□ Goal: For each sample point, get a loss function close as possible to zero


□ Define risk function (aka objective function or cost function)

$$R(\omega) = \sum_{i=1}^n L(X_i \cdot \omega, y_i) = \sum_{i \in V} -y_i X_i \cdot \omega$$

Ces approches supposent que les classes sont séparables par un hyperplan. Plus on augmente le nombre d'attributs dans le jeu de données, moins il y a de chance que cela soit vrai malheureusement... D'autres approches seront donc plus efficaces dans ce cas comme les approches à base de réseaux de neurones par exemple.

Métriques de performance

En classification (ici on reste en binaire mais dans le WS cela a été étendu au multiclasse), on ne peut plus utiliser une métrique comme RMSE pour évaluer la performance de notre modèle sur le jeu de données de test mais d'autres indicateurs comme l'exactitude (accuracy), le taux d'erreur, la précision, le recall.



The loss used for model fitting is typically not the best evaluation metric.

	Truth	
	1	0
Prediction 1	True positive (TP)	False positive (FP)
Prediction 0	False negative (FN)	True negative (TN)

Accuracy: $(TP + TN) / n$
 Error rate: $(FP + FN) / n$
 Precision: $TP / (TP + FP)$
 Recall: $TP / (TP + FN)$



The most obvious/common evaluation metric

Used when detecting rare outcomes

```
1 from sklearn.model_selection import cross_val_predict
2 y_train_pred = cross_val_predict(sgd_clf, X_train, y_train_5, cv=3) #Cette fonction
  permet d'obtenir, pour chaque fold du jeu d'entraînement, les prédictions obtenues en
  apprenant sur le reste des données.
3
4 from sklearn.metrics import confusion_matrix
5 confusion_matrix(y_train_5, y_train_pred)
6
7 from sklearn.metrics import precision_score, recall_score
8 precision_score(y_train_5, y_train_pred)
9 recall_score(y_train_5, y_train_pred)
10 #plus de mesures/courbes sont disponibles dans la solution de WS
```

ROC Curves & AUC

- ❑ A ROC Curve is away to evaluate your classifier after it is trained
- ❑ It is made by running a classifier on the test set or validation set
- ❑ It shows the rate of false positives vs. True positives for a range of settings
- ❑ The axis are
 - ❑ X-axis: « false positive rate = % of negative (-) classified as positives (+)
 - ❑ Y-axis: « true positive rate » = % of positive (+) classified as negatives (-) (aka sensitivity)
- ❑ Other metrics
 - ❑ False negative rate : vertical distance from curve to top = 1 - sensitivity
 - ❑ specificity : horizontal distance from curve to right = 1 - false positive rate



LINEACT

55

Questions pour l'Équipe

1. Quelles caractéristiques du dataset semblent les plus pertinentes pour la tâche de classification et pourquoi ?
2. Quels sont les principaux défis rencontrés lors de la préparation des données et comment les avez-vous surmontés ?
3. Quels critères avez-vous utilisés pour choisir les modèles de classification à tester ?
4. Quels sont les résultats des différentes métriques d'évaluation et comment interprétez-vous ces résultats ?
5. Comment avez-vous assuré la validation et la robustesse des modèles développés ?
6. Quels sont les avantages et les limitations des modèles choisis pour la classification des biens vendus dans les 6 mois ?

Solution

cf. correction du WS pour une approche globale.

2. Workshop du prosit 3

2.1. Sujet

a) Énoncé

i) Exercice

WS P3 : Classification

(cf. WS_Classification.ipynb)

2.2. Guide pédagogique

a) Corrigés-types

Notebooks Jupyter pour le WS, le premier est la version tuteur.

(cf. WS_3_Classification_Tuteur.ipynb)

a) Ethique

i) Etude de cas

1 Situation initiale

- Prendre connaissance de la situation
- Repérer les mots clés, les points importants
 - les faits
 - les paramètres
 - les contraintes
- Définir le but, l'objectif
- Reformuler le contexte

ii) Etude de cas

1 Solutions

- En brainstorming, noter TOUTES les solutions imaginables
- Ne pas écarter tout de suite certaines solutions gênantes ou embarrassantes
- Se limiter dans le temps pour la réflexion



iii) Etude de cas

1 Parties prenantes

- En brainstorming rapide, identifier toutes les « personnes » concernées par chacune des solutions (physiques ou morales)



iv) Etude de cas

1 Impacts

- Par chaque solution possible, lister les impacts ou conséquences pour chacune des parties prenantes
 - Avantages
 - Inconvénients > associer les mesures à mettre en œuvre pour contrer ou minimiser



v) Etude de cas

1 Filtre éthique

- Pour chacune des parties prenantes, à chaque solution, noter les points remarquables au regard des valeurs du vivre ensemble
 - Respecte les personnes?
 - Est altruiste, loyale, universelle, désintéressée?
 - Se base sur des valeurs: fondées, partagées, partageables?

- Est transparente (notamment peut-être rendue publique, présentée aux parties prenantes, etc.)?
- Respecte la loi?
- Est en accord avec la conscience des décideurs?
 - Benoit, Jacques. Pédagogie De L'éthique: Le Coeur Du Développement Durable Est Le. EMS, 2005.p.41
- Est bienveillante?
- Contribue à de la justice?
- Est absente de malveillance?
 - Beauchamp T.L., Childress J.F. 1994



vi) Etude de cas

1 Décision

- A partir des éléments vus précédemment:
 - Go? No Go?
- Repères pour décisions de groupe:
 - Décision collégiale intégrant les parties prenantes ou leurs représentants
 - Information complète de chacun des participants
 - Prise de parole authentique de chacun des participants
 - Avis exprimé par chacun des participants
 - Non-jugement des personnes
 - Débat contradictoire
 - Consensus recherché avec vérification de son authenticité (pas de contrainte de l'un sur l'autre, ni de soumission, ni de manœuvre masquée ou partisane, etc.)
 - Inspiré de: Morel, Christian. Les décisions absurdes: Tome 2, Comment les éviter. Editions Gallimard, 2012



vii) Etude de cas

1 Décision

- Une fois la solution choisie, on vérifie une dernière fois la démarche éthique:
 - Y a-t-il eu un dialogue avec les personnes impliquées par la décision?
 - Suis-je en accord avec la décision? Suis-je en paix avec moi-même en la mettant en œuvre?
 - Ai-je bien tous les paramètres? (en ai-je parlé avec des personnes compétentes?)
 - Est-ce équilibré? Judicieux?
 - Ai-je bien identifié toutes les conséquences pour les autres?
 - Ma décision est-elle responsable?
 - Suis-je au clair sur ce qu'apporte ma décision aux autres?
 - Ma décision est-elle dans l'éthique (altruiste, loyale, universelle, gratuite) ?
 - Serai-je à l'aise pour parler à d'autres de ma décision et de ses conséquences sur autrui?
 - Ma décision est-elle en harmonie avec une loi d'empathie?
 - Si j'étais à leur place, accepterais-je les conséquences que ma décision a sur les autres?
 - Ai-je épuisé toutes les possibilités d'amélioration de ma décision?
 - Serai-je fier d'en parler à mes enfants? Petits-enfants?
 - Etc.
- Inspiré de Benoit, Jacques. Pédagogie De L'éthique: Le Coeur Du Développement Durable Est Le. EMS, 2005.
- Legault. Professionnalisme et délibération éthique: manuel d'aide à la décision responsable. Presses de l'Université du Québec, 2005.



viii) Etude de cas

1 Bilan étude de cas

Résultat

Facilités et difficultés

Ressentis

Pour le futur

ix) Problématiques

1 Médias

- Médiator
- Prothèses mammaires
- Viande de cheval dans les plats préparés
- Espionnage NSA
- Logiciel pour falsifier les tests d'émission de CO₂ Volkswagen
- Etc.

x) Problématiques

1 Exemples de situation dans la vie professionnelle

- Demander à un informaticien de modifier des informations dans la base de données comptables / dans un dossier médical informatisé
- Accorder des droits à un VIP sans passer par la procédure habituelle
- Sollicitation pour constituer un dossier afin de licencier quelqu'un
- Demande de la direction pour connaître qui a ouvert tel document
- Fournir des informations uniquement à l'un des répondants à un appel d'offre
- Couvrir une faute professionnelle d'un collègue (cette faute touche à la sécurité des personnes)
- Profiter de ses droits d'administrateurs pour aller voir ce que des utilisateurs font



xi) Problématiques

Et dans la vie de promo?

Et dans la vie associative?



xii) Bibliographie

- Benoit, Jacques. Pédagogie de l'éthique: Le cœur du développement durable est le « développement durable » du cœur. EMS, 2005.
- Dherse, Jean-Louis, et Hugues Minguet. L'Ethique ou le chaos? Presses de la Renaissance, 1999.
- Didier, Christelle. Les ingénieurs et l'éthique: Pour un regard sociologique. Hermes Science Publications, 2008.
- Didier, Christelle. Penser l'éthique des ingénieurs. Presses Universitaires de France - PUF, 2008.

- Droit, Roger-Pol. L'éthique expliquée à tout le monde. Seuil, 2009.
- Falque, Laurent, et Bernard Bougon. Pratiques de la décision - Développer ses capacités de discernement. 3e éd. Dunod, 2013.
- Kourilsky, Philippe. Le Temps de l'altruisme. Odile Jacob, 2009.
- Le Cardinal, Gilles, Jean-François Guyonnet, et Bruno Pouzoullic. Dynamique de la confiance-construire la coopération dans les projets complexes. Dunod, 1997.
- Legault. Professionnalisme et délibération éthique: manuel d'aide à la décision responsable. Presses de l'Université du Québec, 2005.
- Lecomte, Jacques. Donner un sens à sa vie. Paris: Editions Odile Jacob, 2007.
- Lecomte, Jacques. La bonté humaine. Altruisme, empathie, générosité. ODILE JACOB, 2012.
- Lehrer, Jonah. Faire le bon choix: Comment notre cerveau prend ses décisions. Robert Laffont, 2010.
- Madoz, Jean-Pierre. Ethique professionnelle. AFNOR, 2007.
- Morel, Christian. Les Décisions Absurdes: Sociologie Des Erreurs Radicales Et Persistantes. Gallimard, 2002.
- Morel, Christian. Les Décisions Absurdes: Tome 2, Comment Les Éviter. Editions Gallimard, 2012.
- Pattakos, Alex. Découvrir Un Sens à Son Travail: D'après Les Théories De Viktor Frankl, Auteur De Découvrir Un Sens à Sa Vie. Les Editions de l'Homme, 2006.
- Ricard, Matthieu. Plaidoyer pour l'altruisme: la force de la bienveillance. Nil., 2013.
- Serreau, Yann. Accompagner La Personne En Formation. Paris: Dunod, (2013).