



PROJET IA

Prédiction d'Attrition Employés



HumanForYou



Rayan GOUADFEL



Fabien ARRIGHI



Enzo MARCELLI

Sommaire

01  Contexte

02  Données à disposition

03  Préparation des données

04  Méthodologie IA

05  Clustering

06  Modèles de Régression

07  Modèles de Classification

08  Éthique

09  Conclusion



01.

Contexte

Contexte



HumanForYou



Industrie pharmaceutique



Implantation en Inde



4 410 employés



**Taux d'attrition
annuel**

16.12%

711

départs

3 699

présents



OBJECTIF DU PROJET

Exploiter les données RH pour **identifier les facteurs clés d'attrition** et construire un **modèle prédictif du risque de départ**



02.

Données à disposition

Données à disposition



General Data

4 410 × 24 **Principal**

Données employés : âge, revenu, poste, expérience...



Employee Survey

4 410 × 4 **Satisfaction**

Enquête employés : satisfaction travail, équilibre vie pro/perso



Manager Survey

4 410 × 3 **Évaluation**

Enquête managers : performance, implication



In/Out Time


4 410 × 262 **Badgeage**

Temps de présence journalier sur 262 jours ouvrés



Total : 4 410 employés | 293 colonnes brutes

Valeurs manquantes



Statistiques descriptives

Variable	Moyenne	Médiane	Éc.-type	Min	Max
 Age	36.9	36	9.1	18	60
 MonthlyIncome	65 029	49 190	47 069	10 090	199 990
 TotalWorkingYears	11.3	10	7.8	0	40
 YearsAtCompany	7.0	5	6.1	0	40
 DistanceFromHome	9.2	7	8.1	1	29
 Statistiques descriptives des principales variables numériques du dataset					

Variables catégorielles



Attrition

Yes / No

83.9% No, 16.1% Yes (711 départs)



Department

R&D / Sales / HR

R&D: 2 883 (65%) • Sales: 1 204 (27%) • HR: 189 (4%)



Gender

Male / Female

Male: 2 646 (60%) • Female: 1 764 (40%)



MaritalStatus

3 modalités

Married: 2 019 (46%) • Single: 1 196 (27%) • Divorced: 673 (15%)



BusinessTravel

3 modalités

Rarely: 3 129 (71%) • Frequently: 840 (19%) • Non: 441 (10%)



EducationField

6 modalités

Life Sciences: 1 818 (41%) • Medical: 1 422 (32%)



JobRole

9 modalités

Sales Executive: 978 • Research Scientist: 876 • Laboratory Technician: 775 • Manufacturing Director: 557



03.

Préparation des données

Préparation des données



Fusion des tables

3 tables RH fusionnées sur EmployeeID



Suppression colonnes constantes

EmployeeCount, Over18, StandardHours



Imputation des NaN

Médiane pour numériques, mode pour catégorielles



Feature Engineering

Calcul moyenne badgeage journalière



Dataset

4 410

lignes

27

colonnes




Dataset nettoyé et prêt pour modélisation



0 valeur manquante après imputation

Pipeline de prétraitement



Transformation badgeuse



~9.5% NaN badgeuse = conges / absences (imputes ensuite)

Encodage One-Hot

6 variables catégorielles

BusinessTravel (3)

Department (3)

EducationField (6)

Gender (2)

JobRole (9)

MaritalStatus (3)


One-Hot
Encoding

26 colonnes binaires (0 / 1)

	Travel_Rarely	Travel_Freq.	Travel_Non	Dept_RD	Dept_Sales	Dept_HR	Gender_M	Gender_F	Role_SalesExec	Role_Research	...
Emp. 1	1	0	0	1	0	0	1	0	0	1	...
Emp. 2	0	1	0	0	1	0	0	1	1	0	...
Emp. 3	1	0	0	1	0	0	1	0	0	0	...

27 colonnes avant --> 46 colonnes après encodage

Jeux de données Train / Test



Split stratifié : Ratio 16% Attrition conservé dans train et test

StandardScaler fit uniquement sur le train



04.

Méthodologie IA

Types d'apprentissage en IA



Supervisé

Données étiquetées
Ex: Classification,
Régression



Non Supervisé

Découverte de structures
cachées
Ex: Clustering, PCA



Semi-Supervisé

Combine les deux
approches
Quand labels sont rares

Approche IA choisie



Objectif Business

Réduire l'attrition et **mieux cibler les actions RH**



Non Supervisé

KMeans • Découverte des profils/groupes employés



Supervisé

Classification • Prédiction du risque de départ



05.

Clustering

Qu'est ce que KMeans ?



Algorithme de Clustering

Regroupe les employés par **similarité**



Objectif

Minimiser l'**inertie intra-cluster**

1

Initialisation des centroids

2

Assignment des datas aux clusters les plus proches


3

Mise à jour des centroids

4

Répéter jusqu'à convergence

Comparaison des clusters




Méthode du Coude

Principe

Tracer l'**inertie** en fonction de k

Décision

$k = 3$ au point de coude



Méthode Silhouette




Score Silhouette


Qualité du clustering : **cohésion** vs **séparation**

Validation $k=3$

Score maximal : **0.1366**



Nombre idéal de Clusters



Cluster 0

642 employés
18.7% attrition

Cluster 1

1 020 employés
11.2% attrition

Cluster 2

2 748 employés
17.4% attrition

Σ

06.

Modèles de Regression

Modèles de Régression

Objectif


Prédire l'attrition

Modèles testés

- Régression linéaire
- ElasticNet
- Bayesian Ridge

Observation

Les modèles de régression renvoient des valeurs continues



Modèles de Régression

Age	Attrition	BusinessTravel	Department	DistanceFromHome	Education	...
51	No	Travel_Rarely	Sales	6	2	...
31	Yes	Travel_Frequently	Research & Development	10	1	...
32	No	Travel_Frequently	Research & Development	17	4	...
38	No	Non-Travel	Research & Development	2	5	...
32	No	Travel_Rarely	Research & Development	10	1	...
...	...	...	...	...	...	...



07.

Modèles de Classification

Modèles de Classification



Objectifs de cette phase



- Comparer les performances des modèles
- Identifier le meilleur compromis entre :
 - Précision globale
 - Détection des départs
 - Robustesse et généralisation





Modèles testés

- LogisticRegression
- Perceptron
- SVC (Support Vector Classifier)
- KNN (K-Nearest Neighbors)
- NaiveBayes
- DecisionTree
- RandomForest


Modèles de Classification



Modèles de Classification



Modèles de Classification



Comparaison des modèles

Modele	Accuracy	Precision	Recall	F1	AUC
RandomForest	91.6%	75.2%	71.4%	73.3%	0.952
SVM	91.3%	88.9%	52.6%	66.1%	0.936
NaiveBayes	82.5%	45.2%	39.4%	42.1%	0.763
Perceptron	81.3%	41.0%	37.6%	39.2%	0.735
LogisticRegression	85.6%	62.2%	26.3%	37.0%	0.809
KNN	83.1%	46.1%	27.7%	34.6%	0.875
DecisionTree	85.1%	72.2%	12.2%	20.9%	0.729



08.

Ethique

Éthique

Transparence

Modeles explicables
Documentation complete
Correlation != causalite

Discrimination

Audit fairness
sous-groupes
Tests avec/sans
variables sensibles

Deshumanisation

Aide a la decision
Revue humaine obligatoire
Pas de scoring individuel

Securisation

Donnees anonymisees
Acces restreint
RGPD conforme

Cout environnemental

Modeles legers
Pas de deep learning
Empreinte minimale

Conformite UE | Methodologie CESI 7 etapes | 5 piliers ethiques appliques au projet

Éthique – Détails



Transparence

Modèles explicables, documentation complète, corrélation $\neq$ causalité



Discrimination

Audit fairness par sous-groupes (célibataires 25.5% vs mariés 12.5% attrition), tests avec/sans variables sensibles



Déshumanisation

Outil d'aide à la décision uniquement, revue humaine obligatoire, aucun scoring individuel communiqué



Sécurisation

Données anonymisées (EmployeeID), accès restreint, conforme RGPD, seuil minimal 50 individus par sous-groupe



Coût environnemental

Modèles légers (scikit-learn), pas de deep learning, empreinte carbone minimale




Conformité UE : 7 exigences d'IA digne de confiance respectées



09.

Conclusion

Facteurs clés d'attrition



★ Top 3 : YearsWithCurrManager (-), avg_work_hours (+), TotalWorkingYears (-)

● Rouge = augmente le risque ● Bleu = réduit le risque

Synthèse

RandomForest

Accuracy

91.6%

Precision

75.2%

Recall

71.4%

F1-score

73.3%

AUC

0.952

Impact Business

 Aide à la décision RH
Outil prédictif pour les managers

 Réduction coûts turnover
Identification proactive des risques

Actions préventives ciblées
Stratégies RH personnalisées

Pipeline Complète

Exploration → Préparation

Clustering → Classification

Employés analysés

4 410

Colonnes finales

46

Modèles comparés

7